

miniFlink ex07

Сервис локации и газовых алертов для подземной шахты:
пошаговый разбор архитектуры

Аннотация

ex07 — самый большой пример в репозитории miniFlink. Он строит сервис для подземной угольной шахты, который из двух независимых потоков (пакеты от фонарей и пакеты от газовых датчиков) выдаёт три типа выходов: алерты состояния шахтёра, локацию по маякам связи и обогащённые координатами газовые алерты. Под капотом используется почти весь арсенал библиотеки: скользящие окна с `allowed_lateness`, `group_by`, FSM через `process_keyed`, объединение потоков с выравниванием `watermark`, `retract`-семантика для обновлений.

Эта статья — подробный разбор того, *зачем* каждое решение принято таким, как оно принято: какие альтернативы рассматривались, почему отброшены, что бы случилось при наивной реализации. Цель — дать инженеру, выбирающему stream processing, конкретный материал для оценки, а контрибьютору — понимание design-rationale.

Содержание

1	Задача	1
1.1	Что должен делать сервис	1
1.2	Что в этой задаче сложного	2
1.3	Почему через библиотеку, а не «просто кодом»	3
1.4	Что есть готового в miniFlink	4
1.5	Что увидим дальше	5
2	Входы	5
2.1	Два независимых потока, а не один	5
2.2	Структура RSSI-пакета	6
2.3	Структура газового пакета	6
2.4	Дрожание канала	7
2.5	Large_mine: масштабная конфигурация	7
3	Три пайплайна	8
3.1	connectivity_alerts: три слоя FSM	8
3.1.1	Слой 1: Last_seen	9
3.1.2	Слой 2: Fsm	9
3.1.3	Слой 3: Self_timer	10
3.1.4	Склейка через process_keyed	10
3.2	median_rssi: скользящие окна и интерполяция координат	11
3.2.1	Шаги пайплайна	11
3.2.2	Линейная интерполяция координат	13
3.2.3	Single-beacon fallback	14
3.2.4	Собирая всё вместе	15
3.3	gas_alerts: три потока и retract вручную	15

3.3.1	Что хотим	15
3.3.2	Почему не window join	16
3.3.3	Три потока на входе	16
3.3.4	Состояние per-шахтёр	17
3.3.5	Шесть случаев на одном газовом пакете	17
3.3.6	Refresh при обновлении позиции	18
3.3.7	Почему руками, а не process_keyed	19
3.3.8	Главный сценарий: позиция приходит позже газа	20
4	Retract как сквозной механизм	20
4.1	Что такое retract семантически	21
4.2	Три места эмиссии в ex07	21
4.3	Sink: материализация через Pipe.materialize	22
4.4	Альтернатива: append-only stream	22
4.5	Цена retract'a	23
4.6	Когда retract не нужен	23
5	Производительность	24
5.1	Что меряем	24
5.2	Sequential baseline и переход на OCaml 5	24
5.3	Hashtbl миграция: 1.63x на одном ядре	25
5.4	Параллелизация median_rssi через fan_out	25
5.5	connectivity_alerts: коленом в dispatcher	26
5.6	Суммарный эффект	27
5.7	Что не оптимизируем намеренно	27
6	Выводы	27
6.1	Что построено	27
6.2	Что отложено намеренно и зачем нужно для прода	28
6.3	Что не отложено, а просто не нужно	29
6.4	Когда брать stream processing подход	29
6.5	Финальная мысль	30

1 Задача

Представьте себе подземную угольную шахту: километры тоннелей на нескольких горизонтах, в среднем по сорок-сто шахтёров на смену, у каждого фонарь, который раз в пятнадцать секунд шлёт радиопакет с показаниями нескольких ближайших маяков связи, а раз в десять секунд — отдельный пакет с показаниями газовых сенсоров. Эти пакеты летят в диспетчерскую через 802.15.4 mesh-сеть, развёрнутую внутри шахты, с выходом через ВОЛС-Ethernet коммутаторы на пограничных узлах в магистральную сеть, доходят с задержками, иногда дублируются, иногда теряются.

В диспетчерской на стене висит экран с картой шахты и состоянием смены: где находится каждый шахтёр, у кого тревога по газу, кто прижал кнопку SOS, у кого вот-вот сядет батарейка фонаря. Этот экран обслуживает наш сервис.

1.1 Что должен делать сервис

Если разложить требования *диспетчера* на конкретные пайплайны, получается три независимых подсистемы:

Контроль состояния шахтёра. Из RSSI-пакета извлекаем не показания маяков (это работа другой подсистемы), а *косвенные факты*: пакет вообще пришёл, в нём были показания, фонарь двигался, напряжение батареи в норме. По каждому из этих фактов держим независимый таймер и эмитим соответствующий алерт когда таймер перевалил порог: “не было пакетов больше двух минут”, “пакеты идут, но маяков не слышит больше пяти”, “не двигался дольше порога”, “батарея ниже 3,5 В с дребезгом по гистезису”. Плюс импульс SOS (нажатая кнопка) — мгновенный без таймера.

Локация по маякам. Для каждого шахтёра в скользящем 60-секундном окне с шагом 5 секунд берём топ-2 маяков с самой сильной медианной RSSI и из них приближённо вычисляем координаты шахтёра через интерполяцию между двумя маяками пропорционально расстоянию. Окно скользит каждые 5 секунд, поэтому диспетчерский экран обновляется не реже чем раз в 5 с; при опоздавшем пакете окно *переоткрывается* и эмитит **Retract** старого значения с последующим обновлённым **Data** — так картинка остаётся консистентной.

Газовые алерты с обогащением координатами. Газовый пакет приходит *отдельно* и сам по себе не несёт ID маяков или позиции. Когда газ превышает порог — алерт идёт немедленно (безопасность важнее красоты), но без координат, если их ещё не было. Как только локация для этого шахтёра становится известна (хотя бы по одному маяку), алерт автоматически *обновляется*: старая версия без координат retract’ится, новая с координатами эмитится. То же самое при смене уровня опасности (Warning → Critical) или существенном изменении ppm. Когда газ возвращается в норму — алерт снимается через **Gas_resolved**.

Эти три подсистемы независимы по бизнес-логике, но обмениваются данными: газовый пайплайн *потребляет* результат пайплайна локации, чтобы обогатить свои алерты координатами.

1.2 Что в этой задаче сложного

Если бы это была учебная задача из курса по базам данных, её можно было бы решить за полчаса: батчевый ETL раз в минуту, JOIN по шахтёру, отрисовка в дашборд. Но в реальной шахте такое решение *бесполезно*, и причин этому несколько.

Время событий не равно времени поступления. Пакет от шахтёра M1 с временной меткой **t=88s** может прийти в диспетчерскую в момент **t=210s**: mesh-сеть в шахте может перестроиться когда габаритная техника перекрывает радиолинки между узлами, и узлам приходится искать новый маршрут; АСК теряются и узлы повторяют передачу; на пограничных ВОЛС-коммутаторах — свои буферы и очереди. Если мы будем считать алерты по wall-clock времени поступления, то получим “M1 не двигался последние 2 минуты” в момент когда M1 уже давно дома — его пакет о движении просто опаздывает по дороге. Сервис должен работать по *event-time* (времени самого события), а не по wall-clock.

Идемпотентность. Тот же at-least-once механизм даёт дубликаты: один и тот же пакет может прийти дважды, потому что mesh-узел или ВОЛС-коммутатор ретранслировал его при потерянном АСК. Если мы будем считать тревогу по второму дубли “независимо”, получим *два* алерта SOS на одно нажатие кнопки. Диспетчер не должен видеть фантомных тревог.

Опоздавшие пакеты ломают окна. Окно [60s, 120s) закрылось в 120с, и пайплайн эмитнул финальное топ-2 маяков. Но в 145с пришёл опоздавший пакет с **ts=90s** — он *принадлежит* уже закрытому окну. Нужно либо его выбросить (теряем данные), либо переоткрыть окно, пересчитать агрегат и эмитнуть новое значение, помечая старое как недействи-

тельное. Второе правильно для диспетчера; первое было бы дешевле, но даёт непредсказуемый дашборд (на одной и той же временной метке могут быть разные значения в разные моменты wall-clock).

Газовый алерт без координат лучше чем нет алерта. Газ начинает выделяться *раньше* чем шахтёр успевает прийти под маяк — особенно в забое, где маяки ставят редко. Если ждать координат прежде чем эмитить тревогу о 120 ppm CO, можно потерять минуты на ожидании. Алерт идёт сразу. Но как только координаты появляются — они должны *подтянуться* к уже существующей тревоге, не порождая дубль и не давая диспетчеру повод закрыть старый алерт и открыть новый вручную.

Объём. Шахта на сорок шахтёров — мелочь. Реальные большие шахты в Кузбассе или Караганде имеют до четырёх тысяч работников в смену. RSSI-пакетов от такой шахты получается порядка 270 ev/s, газовых — ещё 400 ev/s. Это немного по меркам стримов, но *пайплайн должен держать нагрузку с запасом*: пиковые моменты (несколько горящих участков одновременно, импульсные помехи от шахтной техники, перестроение большого сегмента mesh когда габаритная техника перекрывает радиолинки между узлами, перезапуск пограничного коммутатора) дают взрывы в десятки тысяч событий в секунду на короткий период. Сервис не должен в эти моменты терять алерты.

1.3 Почему через библиотеку, а не «просто кодом»

Каждый описанный выше пункт сложности *можно* решить вручную: структуры данных в OCamI есть, потоки тоже, таймеры в Unix доступны, голый код пишется. Но есть несколько мест, где «можно вручную» означает *можно сделать так, что в проде это работать не будет*. miniFlink в каждом из них берёт на себя самую тонкую часть.

Event-time и watermark. Без явной модели событийного времени любая обработка с окнами и таймерами скатывается к *wall-clock*: «считаем средний RSSI за последнюю минуту по часам в нашем сервере». В шахте это даёт явные ошибки: пакет с `ts=88s` физически пришёл к сервису в `210s` (retry в mesh + буферизация на пограничном ВОЛС-коммутаторе + очереди в магистрали), и попадает в окно для текущей минуты, искажая её. miniFlink требует чтобы в потоке шли явные **Watermark**-события и каждый оператор окон работал по ним. Голый аналог пришлось бы писать самому, причём правильно: проверять ordering, перепроверять для каждого нового пайплайна, тестировать для каждого варианта late-семантики.

Retract как первоклассное событие. `allowed_lateness` в `window_agg_keyed` даёт нам *автоматический* retract: опоздавший пакет, который попадает в уже закрытое окно (в пределах `allowed_lateness`), вызывает **пересчёт** окна и эмиссию **Retract** старого значения плюс новый **Data**. Голый код имеет два пути: либо просто дропать опоздавшие пакеты (теряем данные ради простоты), либо пересчитывать без retract’ов (диспетчер видит мигание значений на дашборде, потому что окна *переоткрываются* молча). Третий правильный путь — сделать retract как явное событие — это и есть то, что библиотека реализует один раз и для всех пайплайнов.

Дедупликация по бизнес-правилу. Узлы mesh-сети ретранслируют пакеты при потере АСК; ВОЛС-коммутаторы на границе могут дополнительно дублировать на uplink при retry — в любом случае получаем дубли. Наивное “**HashSet** по сериализованным байтам” сломается мгновенно: ВОЛС-коммутатор обогащает пакет полем `received_at`, и идентичные по

смыслу пакеты различаются на байтовом уровне. `Pipe.dedup` берёт правило вида `p.lamp ^ string_of_int p.ts` — ключевое поле бизнеса, не байты транспортного протокола.

State per-key + automatic cleanup. `Pipe.process_keyed` держит state per-key (по шахтёру), вызывает наш обработчик, поддерживает self-timer'ы для timeout- семантики (alert после двух минут тишины). На четырёх тысячах шахтёров голый код потребует свой `Hashtbl<lamp, state>`, ручную регистрацию таймеров, ручную очистку state после конца смены. Каждое из этого — источник багов; например, мы могли бы накопить state шахтёров прошлой смены и тек уть память. Библиотека предоставляет TTL-state из коробки.

Channel с backpressure. Перестроение большого сегмента mesh-сети когда крупная техника (комбайн, скрепер) проходит через выработку и последовательно перекрывает радиолинки между несколькими узлами — узлы накапливают буфер пакетов пока новые маршруты не утвердятся, потом разом выдают накопленное. Голый in-memory pipe без блокировки на upstream получает OOM, когда downstream не справляется. `Pipe.channel` в `miniFlink` имеет явный capacity — producer блокируется когда capacity исчерпан. Пограничный коммутатор дольше держит соединение, mesh-узлы дольше буферизуют, но сервис *не падает*.

Объединение потоков с выравниванием watermark'а. Газовый пайплайн потребляет три источника — raw RSSI, окна локации, газ. У каждого свой event-time и свои watermark'и. Если их просто “склеить” (`Stream.append`), один поток обгонит другие, и состояние обогатится событиями “из будущего”. `Mf_event.union` выравнивает watermark по минимуму из подключенных потоков — ровно та семантика которая нужна, и которую *очень неприятно* писать руками каждый раз.

Параллелизация задним числом. Самое заметное. Изначальный `ex07` написан в однопоточном виде. Добавление параллельной обработки — это одна обёртка `Parallel.run_parallel_simple` вокруг готового пайплайна, без изменения бизнес-логики; см. раздел 5, где показано как одна и та же `Pipelines.median_rssi` ускорила в 4.17 раз на 8 воркерах после такой обёртки. Голый код пришлось бы переписывать, разбираться с гонками, перепродумывать state-shared-vs-per-key. Здесь же исходник остался байт-в-байт тем же.

Тестируемость. `Stream` это просто `unit -> 'a Mf_event.t option`. Тест пайплайна — `Mf_event.of_list ~ts list` с явными временами, потом `Stream.to_list` результата, потом проверка инвариантов. Голый код, использующий системное время и сетевые сокет, потребовал бы моков или медленных интеграционных тестов. У нас наш сложный газовый retract-пайплайн покрыт 7-ю сценариями за <10ms прогона. На уровне самой библиотеки retract/update-семантика, на которую опирается этот пайплайн, дополнительно покрыта property-тестами с независимыми oracle: для произвольных потоков проверяется, что атомарный `Update` эквивалентен паре `Retract+Data`, а финальное состояние окна совпадает с пересчётом по оставшимся элементам — классы инвариантов, которые сценарные тесты структурно пропускают.

Это не «библиотечная польза вообще». Это *конкретные* места, где наивный аналог даёт либо потерю данных, либо нестабильный дашборд, либо невозможность тестов. Каждое исправлять руками дорого; пакет работающих абстракций в `miniFlink` обходится дешевле.

1.4 Что есть готового в miniFlink

Кратко, чтобы не повторяться в дальнейших разделах — ниже полный inventory того, что мы используем в `ex07`:

- `Pipe.event_time ~lateness` — вставка watermark'ов в поток по event-time;
- `Pipe.dedup` — дедупликация по rule-функции;
- `Pipe.window_agg_keyed` с `allowed_lateness` — скользящие окна с retract'ами при опоздавших пакетах;
- `Agg.median`, `Agg.group_by`, `Agg.top_k_by` — набор комбинируемых агрегатов;
- `Pipe.process_keyed` — per-key state с self-timers (для FSM состояния шахтёра);
- `Mf_event.union` — объединение потоков с выравниванием watermark'a по минимуму;
- `Pipe.materialize` — сворачивание retract-богатого потока в финальную таблицу записей (для sink-a).

Чего *нет* — это бизнес-логики и доменных типов. Их пишем мы; структура ниже как раз и есть рассказ о том, как мы их написали.

1.5 Что увидим дальше

Статья идёт от внешнего наружу. В разделе 2 разбираем устройство входов: почему два независимых потока вместо одного, какие в них аномалии. В разделе 3 — три пайплайна по очереди: FSM состояния, скользящие окна с медианой и интерполяцией позиции, retract-обогащение газовых алертов. Раздел 4 собирает наблюдения о retract-семантике как о сквозном механизме, проходящем через все три пайплайна. Раздел 5 приводит измерения производительности (на машине автора-эксперимента и на пользовательском i7-8700 с ОСaml 5) и описывает направленные оптимизации, которые мы делали. Раздел 6 — что отложено, что не делалось намеренно, и при каких условиях стоит реализовать недостающее.

2 Входы

В реальной системе входами выступают Kafka-топики, MQTT-брокеры или сокет — что-то, что принимает потоки с пограничных ВОЛС-Ethernet коммутаторов шахты (за которыми лежит 802.15.4 mesh-сеть на шахтёрах) и дальше отдаёт их потребителю. В ex07 мы заменяем эту инфраструктурную часть на `Mock_source` — модуль, генерирующий *детерминированный* поток событий, неотличимый по форме от прода. Когда сервис переедет в production, `Mock_source` меняется на `Kafka_source.read`, а *остальной код не трогается*. Это центральная идея ex07 — бизнес-логика не привязана к транспорту.

2.1 Два независимых потока, а не один

Первое и самое существенное решение — разнести RSSI-пакеты и газовые пакеты в два разных потока с разными типами.

```
module type S = sig
  val read      : unit -> packet      Mf_event.t Stream.t
  val read_gas  : unit -> gas_packet Mf_event.t Stream.t
  val stats     : unit -> string list
end
```

Почему не сделать единый `type telemetry = RSSI of packet | Gas of gas_packet` с одним потоком `read`? Сובлазн есть: один поток — одна точка консьюминга, проще архитектура источника. Не делаем по трём причинам.

Физически разные устройства. В реальном фонаре RSSI измеряется радиомодулем, газ — отдельным модулем на ремне (часто с собственным batterypack'ом). Они шлют пакеты независимо, как отдельные узлы 802.15.4 mesh. Если объединять их в источнике —

надо объединять прямо на устройстве (фонарь дополнительно слушает газ-модуль), а это *дополнительная* логика на устройстве с ограниченным CPU и батареей. Дешевле оставить два потока.

Разные частоты и разный жизненный цикл. RSSI — 15 секунд между пакетами, газ — 10. Объединение через union-тип создаст поток с *неравномерной* структурой («два RSSI, потом газ, потом RSSI...»), что усложняет понимание timing'a. Раздельные потоки имеют каждый свою регулярность.

Обогащение однонаправленное. Газовый пайплайн *потребляет* результат RSSI-пайплайна (координаты), но не наоборот. Если бы потоки были один, эта зависимость размывалась бы. А так в коде `Pipelines.gas_alerts` прямо принимает `~rssi`, `~locations`, `~gas` тремя именнованными аргументами — видно что от чего зависит.

2.2 Структура RSSI-пакета

```
type packet = {
  lamp      : string;
  readings  : (string * float) list;
  voltage   : float;
  moving    : bool;
  sos       : bool;
  ts        : Time.t;
}
```

`lamp` — идентификатор фонаря, по нему идёт всё партиционирование (один шахтёр == один ключ). `ts` — event-time, миллисекунды от начала смены или от epoch (зависит от deployment).

`readings` — список пар (`beacon_id`, `rssi_dBm`). У шахтёра одновременно слышно от одного до пяти маяков (зависит от того, где он сейчас). Делать отдельную таблицу `packet` → `reading` с FK на пакет, как сделали бы в реляционной базе, нет смысла: пакет существует ровно как единое сообщение от устройства, и в потоке мы будем разворачивать его через `Pipe.flat_map` в плоский поток `reading`ов.

`voltage`, `moving`, `sos` — метаданные о состоянии фонаря, обновляемые на каждом пакете. Это *не показания* в смысле RSSI, а отдельный класс данных (датчик ускорения, ADC батареи, кнопка). Они здесь потому что физически живут в том же пакете: радиомодуль фонаря один раз в 15 секунд просыпается и отправляет всё разом. Логически они потом расходятся по разным пайплайнам.

2.3 Структура газового пакета

```
type gas_packet = {
  g_lamp : string;
  g_ts   : Time.t;
  g_co2  : float option;
  g_co   : float option;
  g_h2   : float option;
  g_ch4  : float option;
}
```

Газы все `option` осознанно. У разных моделей газового модуля разный набор сенсоров: бюджетный имеет только CO и CH₄, дорогой — все четыре. Если бы поля были `float` с магической константой “нет данных” (например, `-1.`), это проникало бы во все downstream пайплайны и рано или поздно пробралось бы в финальный отчёт как “CO = -1 ppm”. С `option` компилятор не даст забыть `match` на `None`.

CO и CO₂ выражаются в ppm; H₂ и CH₄ — тоже, для единообразия (хотя в шахтёрской документации их часто пишут в объёмных процентах: 1% CH₄ = 10 000 ppm).

2.4 Дрождение канала

`Mock_source.Default` специально создаёт реалистичный поток, включая два класса аномалий:

- **Дубли** (около 3% от трафика): тот же (`lamp`, `ts`) приходит дважды. Имитирует at-least-once семантику mesh-узлов (ретрансляция при потерянном АСК) и пограничных ВОЛС-коммутаторов (повторная отправка на uplink при retry).
- **Опоздавшие пакеты** (тоже около 3%): пакет доходит до сервиса *позже* чем должен по event-time. Сдвиг сделан таким, что опоздание превышает размер скользящего окна (≥ 90 секунд) — это гарантирует, что опоздавший пакет попадает в *уже закрытое* окно и порождает retract.

Это не «для красоты тестирования». Это для того, чтобы бенчмарки *отражали прода-нагрузку*. На раннем этапе в репозитории был отдельный `Clean`-источник без аномалий, с обоснованием «бенчмарку нужна стабильная нагрузка». Это было ошибкой: на чистом потоке dedup ничего не дедуплицирует, retract-логика никогда не срабатывает, и измеренный throughput *не отражает* реальной работы. Источник был удалён, а в коммит-сообщении явно записано почему. Этот эпизод хорошо иллюстрирует принцип: бенчмарк должен включать *цену корректности*, иначе он показывает несуществующую скорость, которая исчезает на проде.

2.5 `Large_mine`: масштабная конфигурация

`Mock_source.Default` даёт 6 шахтёров с тщательно проработанными индивидуальными сценариями — этого достаточно для демонстрации и регрессии, но мало для измерения производительности. Параллельно есть `Mock_source.Large_mine` — настраиваемая большая шахта:

```
let default_config = {
  horizons           = 16;
  beacons_per_horizon = 64;
  miners_per_horizon = 256;
  simulation_minutes  = 60;
  step_seconds        = 15;
  gas_period_seconds  = 10;
  pct_no_packets      = 0.10;
  pct_no_readings     = 0.05;
  pct_no_motion       = 0.20;
  pct_low_voltage     = 0.30;
  pct_sos             = 0.01;
  pct_gas_alerts      = 0.05;
  pct_duplicates      = 0.03;
  pct_late            = 0.03;
}
```


Шестнадцать горизонтов по 64 бикона = 1024 бикона; шестнадцать горизонтов по 256 шахтёров = 4096 шахтёров; час симуляции с шагом 15 секунд = около 949 000 RSSI-пакетов плюс газовые (шлются чаще). Это размер реальной большой шахты в Кузбассе.

Каждый шахтёр получает *детерминированный* сценарий через хеш своего ID — такие-то проценты попадают под каждый тип алерта, с непустыми пересечениями (один шахтёр может одновременно ронять батарейку и не двигаться). Детерминированность важна: повторный прогон бенчмарка даёт ровно те же события и ровно тот же результат, можно сравнивать через `git bisect`.

Биконы на горизонте. Маяк связи слышен только на *своём* горизонте — это упрощение, но не очень сильное: на практике межгоризонтная связь через породу настолько слабая, что её обычно специально подавляют, чтобы шахтёры не позиционировались ложно через сигнал с соседнего уровня.

Биконы расставлены *линейно* вдоль штрека через равные интервалы (в `Large_mine` — условно 60 единиц расстояния друг от друга). Каждый шахтёр на своём горизонте слышит до пяти ближайших биконов вдоль линии. RSSI вычисляется детерминированно из расстояния по формуле $RSSI = -40 - 20 \log_{10}(d)$, и обращается обратно в расстояние в пайплайне локации — так `Large_mine` полностью внутренне-согласован.

Дальше мы переходим к самим пайплайнам.

3 Три пайплайна

Три пайплайна образуют ядро сервиса. У каждого свой набор операторов и свои дизайнерские решения, но между ними виден общий стиль: все три потребляют один и тот же `packet`-поток (или его производные), все три используют `event-time`, у всех трёх результат идёт в `sink`-обязку, которая отображает или публикует данные.

Разбираем по одному. Самый простой по семантике, но самый интересный архитектурно — `connectivity_alerts`.

3.1 `connectivity_alerts`: три слоя FSM

Этот пайплайн ловит пять диагностических состояний шахтёра:

- **No_packets** — пакеты от фонаря перестали приходить (> 2 мин тишины);
- **No_readings** — пакеты идут, но **readings** пустой (> 5 мин не слышит ни одного маяка);
- **No_motion** — датчик ускорения молчит (> 2 мин без движения);
- **Low_voltage** — напряжение батареи ниже 3,5 В, держится дольше 2 минут (с гистерезисом возврата 3,7 В);
- **Sos** — кнопка SOS нажата (мгновенно, без таймера).

Любая из четырёх первых тревог снимается, когда условие перестаёт выполняться (для напряжения — с гистерезисом, об этом ниже).

Соблазн монолита. Самое прямое решение — один большой `process_keyed.on_event` с per-key state, в котором аккумулируем «время последнего пакета, время последнего движения, текущее напряжение, флаг что был ли уже `Low_voltage`». На каждом пакете обновляем state, смотрим что изменилось, эмитим алерты.

Это работает, но плохо читается и плохо тестируется. На каждом пакете мы одновременно делаем три разных вещи: **запоминаем факты** (когда последний пакет), **принимаем решения** (нужно ли алертировать), **регистрируем таймеры** (когда проверить тишину снова, если сейчас пакетов нет). Все три смешаны в одной функции, и поправить поведение для одного типа алерта означает читать весь файл.

Разделение на три слоя. Поэтому Pipelines раскладывает FSM на три модуля:

- **Last_seen** — хранилище фактов;
- **Fsm** — чистые функции «факты → алерт»;
- **Self_timer** — регистрация таймеров.

`process_keyed` склеивает их в общий пайплайн, но каждый модуль изолирован и тестируем независимо.

3.1.1 Слой 1: Last_seen

Просто запись того, что мы знаем о шахтёре в данный момент.

```
type t = {
  mutable last_pkt_ts      : Time.t;      (* any packet *)
  mutable last_reading_ts : Time.t;      (* packet with non-empty
    readings *)
  mutable last_motion_ts  : Time.t;      (* packet with moving=true *)
  mutable last_voltage    : float;
  mutable last_voltage_ts : Time.t;
  mutable low_v_since     : Time.t option;
  mutable in_low_v        : bool;        (* for debounce + hysteresis *)
}
```

Метод `record` обновляет нужные поля по приходящему пакету. В нём *нет* логики «что эмитить» — только запоминание.

Этот слой решает проблему «когда таймер сработал в момент молчания, у нас нет пакета чтобы взять из него факты» — факты уже лежат в `Last_seen`.

3.1.2 Слой 2: Fsm

Чистые функции от `Last_seen` к опциональному алерту:

```
let no_packets seen ~now =
  if now - seen.last_pkt_ts > no_packets_threshold
  then Some (No_packets (seen.lamp, seen.last_pkt_ts))
  else None

let no_motion seen ~now = ...
let no_readings seen ~now = ...
let low_voltage seen ~now = ...

(* Aggregate: at what nearest moment in time should we
  re-check the state, assuming no new packet arrives? *)
let next_check seen = ...
```

В этом слое нет state и нет I/O — любая функция здесь принимает `Last_seen.t` и возвращает чистое значение. Тесты пишутся тривиально: «вот snapshot, вот ожидаемый алерт».

next_check как сердце таймера. Самая интересная функция здесь — `next_check`. Она отвечает на вопрос: «если сейчас *не* придёт нового пакета, в какой ближайший момент состояние может измениться?» Например, если последний пакет был в 100с и порог тишины — 2 минуты, то изменение наступит в 220с (100 + 120). Если последнее движение было в 95с — то в 215с. И так далее. `next_check` берёт минимум по всем «пробудкам» и возвращает один timestamp.

Это нужно `Self_timer`'у, чтобы знать, на какой момент будить пайплайн.

3.1.3 Слой 3: `Self_timer`

`process_keyed` в `miniFlink` имеет встроенную поддержку self-timers через `ctx.set_timer`. `Self_timer` тонко оборачивает её, добавляя одну инвариантность: на каждом ключе живой может быть *максимум один* таймер. Когда приходит новый пакет и `Fsm.next_check` даёт новое время будильника, старый таймер отменяется и регистрируется новый. Это уберегает от накопления старых таймеров (особенно опасно для долгоживущих шахтёров).

```
let reschedule t ctx ~target =
  match t.armed with
  | Some old when old = target -> ()      (* same timer *)
  | _ ->
    (* Old timer will be ignored on fire -- we changed 'armed',
       so when it fires the handler sees it's stale. *)
    ctx.Pipe.set_timer target Pipe.Wallclock;
    t.armed <- Some target
```

3.1.4 Склейка через `process_keyed`

```
let connectivity_alerts source =
  source
  |> Pipe.event_time ~lateness:(seconds 1)
  |> Pipe.process_keyed (module ByLamp)
    ~init:make_state
    ~on_event:(fun ctx key st p ->
      (* Layer 1: remember facts *)
      (match Last_seen.record st.seen ~p with
       | 'Sos_pressed -> ctx.emit (Sos (key, p.ts))
       | 'Quiet -> ());
      (* Layer 2 + emission *)
      check_and_emit ctx key st ~now:p.ts;
      (* Layer 3: schedule the next check *)
      Self_timer.reschedule st.timer ctx
        ~target:(Fsm.next_check st.seen))
    ~on_timer:(fun ctx key st t _kind ->
      Self_timer.consumed st.timer;
      check_and_emit ctx key st ~now:t;
      let next = Fsm.next_check st.seen in
      if next > t && next < max_int then
        Self_timer.reschedule st.timer ctx ~target:next)
```

Двадцать строк кода, и каждая строка делает ровно одну вещь. Это прямой эффект разделения: ни одна функция в этом пайплайне не смешивает «помню что было» с «решаю что делать».

Гистерезис напряжения. Один из неприметных, но важных моментов — `Low_voltage` имеет *два* порога: `low_voltage_threshold = 3.5` (вход в подозрение) и `voltage_ok_threshold = 3.7` (выход обратно). Это *гистерезис*: вошёл в `Low_voltage` при $V < 3,5$, вышел только при $V > 3,7$. Между ними — *мёртвая зона*, в которой состояние не меняется.

Без гистерезиса колебания напряжения около 3,5 В (нормальное поведение под нагрузкой фонарика) дали бы *дребезг алертов* — `Low_voltage`, `Voltage_ok`, `Low_voltage`, `Voltage_ok` — много раз в минуту. Диспетчер увидел бы хаос. Один из тех мелких моментов, которые отличают `workable` систему от непригодной.

Дополнительно есть `voltage_debounce = 2` минуты: алерт `Low_voltage` эмитится не сразу как напряжение упало ниже 3,5, а только если оно *держится* там 2 минуты подряд. Это уже не гистерезис, это `debounce` — защита от кратковременных просадок напряжения (включение фонаря на полную мощность даёт мгновенный провал).

Почему такой подход универсален. Каждый раз, когда в проде встаёт задача «детектировать состояние из временного ряда событий», возникают те же три проблемы: а) надо помнить факты; б) надо принимать решения о них; в) надо реагировать на молчание. `Three-layer split` здесь не специфичен для шахты или для `miniFlink` — он будет применим к любой подобной задаче (мониторинг IoT-устройств, `heartbeats` веб-сервисов, `dropped sessions` в чатах). В этом примере он реализуется в идиомах OCaml + `process_keyed`, в Java + `Flink KeyedProcessFunction` был бы тот же `split` в тех же трёх классах.

Дальше переходим к пайплайну локации — архитектурно проще (один длинный `pipe` из операторов), но с насыщенной алгоритмикой: скользящие окна с `retract`’ами, медиана по биконам, `top-2`, и линейная интерполяция координат.

3.2 median_rssi: скользящие окна и интерполяция координат

Задача пайплайна — для каждого шахтёра выдавать «`top-2` маяков с самой сильной медианной RSSI» в скользящем 60-секундном окне с шагом 5 секунд, а из них приближённо вычислять координаты шахтёра в двумерной плоскости горизонта.

Архитектурно это *линейный* `pipe` из операторов; интересна не структура, а каждый отдельный шаг и почему он выглядит так.

3.2.1 Шаги пайплайна

1. dedup по бизнес-ключу.

```
|> Pipe.dedup (module ByLamp)
  ~rule:(fun p -> string_of_int p.ts)
  ~cooldown:(seconds 120)
```

`Pipe.dedup` держит `per-key cache` недавно виденных `rule`-значений и фильтрует повторы. Ключ дедупликации — `(lamp, ts)`, выражаемый как `string_of_int p.ts` в пределах ключа `p.lamp`. Если пакет от M1 с `ts=88s` пришёл дважды (`retry` в `mesh` при потерянном ACK, ретрансляция ВОЛС-коммутатором, `at-least-once Kafka`), мы дедуплицируем по бизнес-ключу *пакета* (`lamp + event-time`), а не по байтовому содержимому сетевого сообщения — которое пограничный коммутатор вполне мог обогатить полем `received_at` перед ретрансляцией.

`cooldown 120s` означает: дедуплицируем дубли в пределах двух минут. Если тот же ключ придёт через 3 минуты — это уже не дубль, а что-то странное (битый `clock` на устройстве?), но пропускаем дальше, не теряя данные.

2. flat_map: разворот в reading'и.

```
|> Pipe.flat_map (fun p ->
  List.map (fun (b, rssi) ->
    { r_lamp = p.lamp; r_beacon = b;
      r_rssi = rssi; r_ts = p.ts })
  p.readings)
```

Каждый пакет имеет от одного до пяти reading'ов. `flat_map` разворачивает один пакет в несколько событий, каждое — запись вида “шахтёр X слышал маяк Y с уровнем Z в момент T”. Дальше работаем с плоским потоком, а не с пакетами.

Почему это правильно: для медианы по бикону нам нужно *сгруппировать* все RSSI данного маяка отдельно, что естественно делается на плоских записях. Если бы оставили пакеты, `group_by` пришлось бы делать по `packet.readings`, и агрегаты усложнились бы.

3. event_time с lateness.

```
|> Pipe.event_time ~lateness:(seconds 1)
```

Вставка watermark'ов на основе event-time каждого reading'a. Параметр `lateness:1s` означает: «watermark отстаёт от максимального виденного event-time на 1 секунду». Это *out-of-order tolerance* между близкими во времени событиями: если у нас сейчас прошло событие с `ts=100s`, watermark поднимется только до 99с, давая 1 секунду на “последние опоздавшие” до того как окно закроется.

Почему именно 1 секунда. В нашем сценарии reading'и сгенерированы из одного пакета с одинаковым `ts` — они синхронны. Out-of-order возникает только между пакетами от разных шахтёров, доставленными через сеть. Эмпирически разброс доставки для неаномальных пакетов укладывается в 1с. Если поставить больше (скажем, 60с) — окна закрываются медленнее, дашборд лагает на минуту. Меньше — теряем близко-опоздавшие. Это типичный out-of-order trade-off; 1с в нашем сценарии нормально, в шахтах с большим числом hop'ов в mesh или частыми перестроениями маршрута может потребоваться 5–10с.

Сама обработка *сильно* опоздавших пакетов (более 60с) лежит на `allowed_lateness` следующего оператора — они переоткрывают окно через `retract`.

4. window_agg_keyed: главный оператор.

```
|> Pipe.window_agg_keyed
  ~by:(fun r -> r.r_lamp)
  ~allowed_lateness:(seconds 60)
  (Pipe.sliding (seconds 60) (seconds 5))
  Agg.(...)
```

Здесь несколько параметров:

- `by` — ключ партиционирования (шахтёр);
- `sliding (60s) (5s)` — окно длиной 60с с шагом 5с, то есть событие $t = 30с$ попадает в окна $[-30, 30)$, $[-25, 35)$, $[-20, 40)$..., $[30, 90)$. Двенадцать окон на событие;
- `allowed_lateness 60s` — если опоздавший пакет попадает в *уже закрытое* окно, но не более чем на 60с прошлое — окно **переоткрывается**, агрегат пересчитывается, эмитится `Retract` старого результата плюс `Data` нового. Пакеты опоздавшие сильнее — идут в side output (мы их не собираем; в проде шли бы в DLQ);
- `Agg.t` — комбинаторно-собираемый агрегат, см. ниже.

Это *единственный* stateful оператор всего пайплайна. Состояние — хеш-таблица «окно → список значений (или сложенный аккумулятор)», очищается автоматически при закрытии окна (или оставляется на время `allowed_lateness`).

5. Двухуровневая агрегация через Agg.

```
Agg.(
  group_by
    ~key:(fun r -> r.r_beacon)
    ~inner:(median (fun r -> r.r_rssi))
  |> map (fun per_beacon ->
    per_beacon
    |> List.filter_map (fun (b, med) ->
      match med with
      | Some m -> Some (b, m)
      | None -> None)
    |> Agg.run (top_k_by 2 ~by:snd)))
```

Внутри одного окна шахтёра M1 у нас может быть, например, 8 reading'ов от B1, 12 от B2, 5 от B3. `group_by key:beacon` группирует их по маяку. `~inner: median` — агрегат, применяемый к каждой группе: для B1 даёт medianX, для B2 — medianY, для B3 — medianZ. На выходе списка пар [(B1, X); (B2, Y); (B3, Z)].

Дальше `map` превращает этот список в top-2 через `top_k_by 2`. У нас два уровня агрегации — сначала медиана внутри маяка, потом ranking между маяками — собранные *декларативно* из библиотечных кубиков, без рукописных циклов.

3.2.2 Линейная интерполяция координат

Имея top-2 маяков с известными координатами и медианной RSSI до каждого, мы хотим приближённо найти координаты шахтёра в плоскости горизонта.

От RSSI к расстоянию. В `Large_mine` RSSI генерируется по формуле $RSSI = -40 - 20 \log_{10}(d)$. Инверсия:

$$d = 10^{\frac{-RSSI-40}{20}}$$

```
let distance_from_rssi (rssi : float) : float =
  10. ** ((-. rssi -. 40.) /. 20.)
```

В реальной шахте этот калибровочный коэффициент зависит от частоты радио, влажности воздуха, рельефа тоннеля, и в проде калибруется эмпирически на каждом горизонте. У нас вшито в код — демо.

Интерполяция между двумя маяками. Имея A с координатами (xa, ya) и расстоянием d_a, B с координатами (xb, yb) и расстоянием d_b, точку на отрезке AB пропорционально расстояниям:

$$t = \frac{d_a}{d_a + d_b}, \quad \text{pos} = (1 - t) \cdot A + t \cdot B$$

```
let interpolate_position ~find_beacon (top2 : (string * float) list)
  =
  match top2 with
  | (b_a, rssi_a) :: (b_b, rssi_b) :: _ ->
    (match find_beacon b_a, find_beacon b_b with
     | Some (xa, ya, ha), Some (xb, yb, _) ->
```

```

let d_a = distance_from_rssi rssi_a in
let d_b = distance_from_rssi rssi_b in
let total = d_a +. d_b in
if total = 0. then Some (xa, ya, ha)
else
  let t = d_a /. total in
  let x = (1. -. t) *. xa +. t *. xb in
  let y = (1. -. t) *. ya +. t *. yb in
  Some (x, y, ha)
| _ -> None
| _ -> None

```

Геометрия тоннеля. Шахтный тоннель — по сути *линия*. Биконы устанавливаются вдоль штрека через равные интервалы (10–30 метров в зависимости от инфраструктуры), образуя *линейный* ряд узлов вдоль оси тоннеля. Шахтёр в любой момент времени находится *в самом тоннеле* — между двумя соседними биконами на этой линии.

Это качественно отличает задачу локации в шахте от наружной локации (улица, склад, открытая местность). В 2D-плоскости снаружи позиция определяется *трилатерацией* — пересечением трёх и более окружностей с центрами в маяках, методом наименьших квадратов по нелинейной системе. В шахтном тоннеле такой алгоритм *не применим*: маяки лежат *на одной прямой*, окружности их зоны покрытия пересекаются *симметрично* относительно оси штрека, и решение нелинейной системы либо неоднозначно (две точки по разные стороны от оси), либо вырождается (бесконечно много решений на оси).

Правильная геометрическая модель для тоннеля — одномерная: “между биконом *A* и биконом *B*, ближе к одному или к другому пропорционально расстоянию”. Это *ровно* то, что делает `interpolate_position`. Линейная интерполяция здесь — не “упрощение для демо”, а *корректный* метод для геометрии задачи.

Источники неточности. Алгоритм правильный, но позиция всё равно приближённая по двум причинам:

- **RSSI шумный.** Между двумя последовательными измерениями того же бикона тем же фонарём при неподвижном шахтёре RSSI колеблется на ± 4 дБ из-за многолучёвости и переотражений в породе. По формуле $d = 10^{(-\text{RSSI}-40)/20}$ это даёт $\sim 50\%$ погрешности в *расстоянии* на каждый отдельный reading. Поэтому мы и берём *медиану* в окне 60с — агрегация устраняет шум до приемлемого уровня.
- **Калибровочный коэффициент.** Формула $-40 - 20 \log_{10}(d)$ параметризована для свободного пространства; в реальном тоннеле обычно -12 дБ за декаду расстояния больше из-за поглощения в породе. Калибровка делается эмпирически на каждом горизонте при вводе шахты в эксплуатацию.

При нормальной работе системы итоговая точность позиционирования — порядка *одной длины пролёта* между биконами (10–30 м). Этого достаточно для главной целевой задачи: “в каком пролёте сейчас шахтёр” для спасательной операции.

3.2.3 Single-beacon fallback

Что делать если в reading’ах шахтёра *один* маяк или ноль? `interpolate_position` вернёт `None`. Но для газового пайплайна это плохо: первый алерт мы можем эмитить вообще без позиции, и хотелось бы хоть какую-то указать.

`single_beacon_position` — вспомогательная функция: берёт `reading` с самым сильным RSSI и возвращает координаты *этого маяка*. То есть «шахтёр где-то рядом с B1, точнее сказать не можем». Точность ниже чем у интерполяции, но это лучше чем `None`.

```
let single_beacon_position ~find_beacon (readings : (string * float)
  list) =
  match readings with
  | [] -> None
  | rs ->
    let (b, _) = List.fold_left
      (fun (_, best) as acc) (_, r) as cur ->
        if r > best then cur else acc)
      (List.hd rs) (List.tl rs) in
    find_beacon b
```

Эта функция используется в газовом пайплайне (раздел 3.3) для обогащения координат *до* того как первое окно RSSI закрылось — сразу после первого raw RSSI-пакета шахтёра.

3.2.4 Собирая всё вместе

Финальный пайплайн:

```
let median_rssi ?(find_beacon = Domain.beacon_coords)
  (source : packet Mf_event.t Stream.t)
  : location Mf_event.t Stream.t =
  source
  |> Pipe.dedup (module ByLamp)
    ~rule:(fun p -> string_of_int p.ts)
    ~cooldown:(seconds 120)
  |> Pipe.flat_map (fun p -> ... (* expand to readings *))
  |> Pipe.event_time ~lateness:(seconds 1)
  |> Pipe.window_agg_keyed ~by:(fun r -> r.r_lamp)
    ~allowed_lateness:(seconds 60)
    (Pipe.sliding (seconds 60) (seconds 5))
    Agg.(group_by ~key:... ~inner:median |> map top_k_by_2)
  |> map_to_location_with_position ~find_beacon
```

Шесть операторов, каждый делает ровно одну вещь. Можно прочитать сверху вниз и понять полный жизненный цикл события. Это и есть обещание stream processing fluent-DSL: пайплайн читается как описание *бизнес-преобразования*, без runtime-деталей про state и таймеры.

Что эмитит этот пайплайн. Поток событий `location Mf_event.t: Data` при закрытии окна, `Retract` плюс новый `Data` при опоздавшем пакете в `allowed_lateness`. `Watermark`'ы продвигаются по event-time.

Sink через `Pipe.materialize` сворачивает поток в *финальную таблицу* «(шахтёр, конец окна) → location» — `retract`'ы автоматически отменяют старые значения. Это позволяет диспетчерскому пульту показывать *актуальную картину*, не флудя на каждом обновлении.

Дальше — самый интересный пайплайн, газовый. У него три потока на входе, и `retract`-семантика не из коробки оператора окон, а написана вручную.

3.3 gas_alerts: три потока и retract вручную

Это самый интересный из трёх пайплайнов, и единственный из них, в котором retract-семантика реализована *вручную*, а не встроенным оператором окна. По дороге заодно отвечаем на исходный вопрос задачи: *если пакеты с координатами приходят позже газа, обновятся ли уже эмитированные алерты?* Ответ — да, через механизм описанный ниже.

3.3.1 Что хотим

Газовый пакет приходит *отдельно* от RSSI-пакета и сам по себе не знает координат шахтёра. Когда в пакете обнаружено превышение порога ($\text{CO} > 50 \text{ ppm}$, $\text{CH}_4 > 5000 \text{ ppm}$, и т.д.) — мы хотим:

- эмитить алерт *немедленно*, не дожидаясь координат (потому что безопасность важнее красоты);
- включить в алерт координаты если они *известны* (из любого источника: грубо из последнего RSSI-пакета, точно из последнего закрытого окна локации);
- *обновить* ранее эмитированный алерт когда координаты становятся доступны или уточняются — через retract старого и emit нового;
- не флудить диспетчера на стабильных показаниях — одно превышение давать один *живой* алерт пока шахтёр в опасной зоне; обновлять алерт только при существенных изменениях.

Это явно *stateful* обработка по ключу (шахтёр + газ), с *временной зависимостью* между двумя независимыми потоками (газ и позиция). Кажется задачей для stream join. Не делаем join по двум причинам.

3.3.2 Почему не window join

В Flink-DSL есть оператор join с временным окном: *смачить* событие из левого потока с событием из правого потока, если их event-time различается не более чем на Δ . Применить к нашей задаче:

- **Задержка алерта.** Чтобы сделать join, нужно *дождаться* пары — газа и позиции. Если газа нет — ждём. Если позиции нет — ждём. Окно длиной 30с означает *до 30 секунд задержки* газового алерта. В шахте при критическом СО это непригодно: алерт нужен сразу, координаты или нет.
- **Дубли при разных частотах.** Газ шлётся каждые 10с, окно локации закрывается каждые 5с. Каждый газовый пакет матчится *несколькими* location-окнами в пределах временного окна join'a. Один газ + 3 близких location-окна = 3 алерта вместо одного. Можно фильтровать “по ближайшему”, но это уже не симметричный join.

То что мы делаем семантически — это *temporal left-join* с особенностью «брать последнее известное, не ждать пары». В Flink-терминах это `KeyedCoProcessFunction` с `ValueState<Position>`: газ — driver, позиция — side input, обновляется в state но не блокирует газ.

3.3.3 Три потока на входе

```
type gas_input =  
  | Position_from_window of location  
  | Position_from_raw    of packet  
  | Gas                  of gas_packet
```

Три варианта одного union-типа. Первые два — разные источники позиции:

- **Position_from_window** — результат `median_rssi`, точная позиция из закрытого 60-секундного окна. *Отстаёт* от реального времени (до минуты), но точнее (медиана RSSI, интерполяция между двумя биконами).
- **Position_from_raw** — грубая позиция от raw RSSI-пакета через `single_beacon_position`. Обновляется *мгновенно* на каждом пакете (раз в 15 секунд), точность — координаты ближайшего бикона (где-то на сфере радиуса d).

Зачем нам *оба*? Чтобы алерты имели координаты с самого первого момента работы сервиса. Без `Position_from_raw` первый газовый алерт после старта смены не имеет координат целую минуту — пока не закроется первое RSSI-окно. С raw-fallback — координаты появляются в первом же газовом алерте после первого RSSI-пакета (то есть в течение 15 секунд).

Три потока сливаются через `Mf_event.union`, выравнивающий watermark по минимуму:

```
let s_loc = locations |> Pipe.map (fun l -> Position_from_window l)
    in
let s_raw = rssi      |> Pipe.map (fun p -> Position_from_raw p) in
let s_gas = gas       |> Pipe.map (fun g -> Gas g) in
let unioned = Mf_event.union (Mf_event.union s_loc s_raw) s_gas
```

Watermark-выравнивание не игрушка. `Mf_event.union` ждёт пока все подключённые потоки продвинут watermark, и только тогда продвигает свой. Без этого один из потоков обогнал бы другие и события «из будущего» обогащали бы state до того как у нас есть «прошлые» события другого потока. Например, газовый пакет $t = 100s$ обработался бы до того как позиционный пакет $t = 80s$ обновил state — алерт ушёл бы без координат, хотя они уже *были известны*. Union с min-watermark гарантирует строгий event-time порядок.

3.3.4 Состояние per-шахтёр

```
type gas_state = {
  mutable position : (float * float * int) option;
  active : (gas, active_alert) Hashtbl.t;
}
and active_alert = {
  aa_level      : gas_level;
  aa_ppm        : float;
  aa_position   : (float * float * int) option;
}
```

`position` — последняя известная координата шахтёра (перезаписывается при обновлении из любого источника позиции). `active` — хэш-таблица «газ → что мы последний раз эмитили по нему», по одному входу на каждый активный алерт. Когда шахтёр в норме по CH_4 , но активен по CO — в таблице один вход (`Gas_CO, ...`).

`active_alert` помнит *что было эмитировано*: уровень, ppm, позиция на момент эмиссии. Это нужно потому что retract должен *в точности повторить* старое событие (включая позицию которая могла измениться) — иначе sink не поймёт что ретракт относится к тому самому раннему алерту.

3.3.5 Шесть случаев на одном газовом пакете

Когда приходит газовый пакет, для каждого газа в нём (CO , CO_2 , H_2 , CH_4 — те что изменены) выполняется `process_one_gas`. Логика разбита на шесть случаев в зависимости от

пары (текущий уровень опасности, был ли активный алерт):

```
match current_level, previous_alert with
```

Случай 1: норма, не было алерта. Ничего не делаем.

```
| None, None -> []
```

Случай 2: норма, был алерт — ситуация улучшилась. Эмитим retract старого Gas_alert + новый Gas_resolved:

```
| None, Some old ->
  Hashtbl.remove st.active g;
  [ Mf_event.retract (Gas_alert {...old...}) ts;
    Mf_event.data     (Gas_resolved {...})      ts ]
```

Gas_resolved — отдельный конструктор. По нему sink понимает что тревога *снята* (а не просто исчезла из ленты). Параллель с Voltage_ok в connectivity — диспетчер видит явное событие «теперь в норме».

Случай 3: превышение, не было алерта — новый алерт.

```
| Some level, None ->
  Hashtbl.add st.active g { aa_level=level; aa_ppm=ppm;
                           aa_position=st.position };
  [ Mf_event.data (Gas_alert {level; ppm; position=st.position}) ts ]
```

Записываем в active что эмитили, эмитим Data.

Случаи 4, 5, 6: был алерт, всё ещё превышение.

```
| Some level, Some old ->
  let level_changed      = level <> old.aa_level in
  let ppm_changed        = ppm_changed_significantly old ppm in
  let position_changed    = st.position <> old.aa_position in
  if not (level_changed || ppm_changed || position_changed) then []
  else (* retract old + emit new *)
```

Три проверки:

- level_changed — Warning стал Critical или наоборот;
- ppm_changed — изменение более чем на 20%;
- position_changed — координаты обновились (главный случай для исходного вопроса задачи).

Если ни одно из условий не выполнено — ничего не эмитим (*sticky* семантика, защита от спама). Иначе — retract старого + emit нового.

Порог 20% на ppm. Сделан конфигурируемым через Domain.gas_ppm_significant_change. Меньше — спам обновлений на каждом колебании датчика. Больше — диспетчер не видит роста опасности. 20% — эмпирический баланс.

3.3.6 Refresh при обновлении позиции

Когда приходит `Position_from_window` или `Position_from_raw`, мы обновляем `st.position`. Но это в одиночку *не* эмитит обновлений уже-активных алертов. Для них нужен явный проход:

```
let refresh_alerts_for_new_position st lamp ts =
  Hashtbl.iter (fun g old ->
    if st.position <> old.aa_position then begin
      (* retract old + data with new position *)
      Queue.push (Mf_event.retract (Gas_alert {...old...}) ts)
        out_buf;
      Queue.push (Mf_event.data      (Gas_alert {...new...}) ts)
        out_buf;
      Hashtbl.replace st.active g { old with aa_position =
        st.position }
    end
  ) st.active
```

Этот проход вызывается *сразу после* обновления `st.position`. Все активные алерты текущего шахтёра получают `retract + emit` с новой позицией. Это и есть *обновление состояния газа уже с координатами* из исходного вопроса задачи.

Порядок приоритетов источников. На `Position_from_window` обновляем безусловно — точная позиция всегда заменяет грубую. На `Position_from_raw` обновляем *только если позиции ещё нет*:

```
| Position_from_raw pkt ->
  (match st.position, single_beacon_position pkt.readings with
  | None, (Some _ as new_pos) ->
    st.position <- new_pos;
    refresh_alerts_for_new_position st pkt.lamp pkt.ts
  | _ -> ())
```

Иначе грубая позиция от raw RSSI *переписала* бы более точную позицию от закрытого окна — и алерты flap'али бы между точной и грубой каждые 15 секунд.

3.3.7 Почему руками, а не process_keyed

`Pipe.process_keyed` — идиоматичный способ построить stateful per-key оператор. Логично было бы использовать его и здесь. Но не получилось.

`process_keyed.on_event` принимает callback с `ctx`, у которого есть `ctx.emit : 'out -> unit`. То есть пользователь эмитит *значение* типа `'out`, а runtime сам оборачивает его в `Mf_event.Data (v, t)`. Это удобно когда мы хотим эмитить только данные.

Но нам нужны `Mf_event.Retract`. Через `ctx.emit` их не выпустить — API не предусмотрен.

Это не баг библиотеки, а сознательное ограничение `process_keyed`: подавляющее большинство stateful операторов эмитит только `Data`, а `retract`'ы порождают *операторы окон* (через `allowed_lateness`). Газовый алерт — *нетипичный* случай, где пользовательский код сам решает когда `retract`.

Поэтому `gas_alerts` написан *вручную*: per-lamp `Hashtbl` для state, `Queue` для накопления исходящих событий, рекурсивный pull по upstream-потoku.

```

let states : (string, gas_state) Hashtbl.t = Hashtbl.create 64 in
let out_buf : gas_alert Mf_event.t Queue.t = Queue.create () in
let process_input = function ... in
let rec next () =
  if not (Queue.is_empty out_buf) then Some (Queue.pop out_buf)
  else match unioned () with
  | None -> None
  | Some (Mf_event.Watermark wm) -> Some (Mf_event.Watermark wm)
  | Some (Mf_event.Retract _) -> next ()
  | Some (Mf_event.Data (input, _ts)) ->
    process_input input; next ()
in next

```

Двадцать строк, и каждая делает ровно одно: либо выдаёт накопленное из буфера, либо подтягивает следующее событие из upstream, либо обрабатывает событие и рекурсивно идёт дальше.

Что это значит для библиотеки. Если бы такой паттерн встречался часто, имело бы смысл расширить `process_keyed` до варианта где `ctx.emit` принимает `Mf_event.t`. Пока это единственный случай, и руками — приемлемо. Архитектурное правило: когда у библиотеки нет ровно нужного API, можно реализовать *по своему*; main concern — читаемость и тестируемость, а не “всё через одну функцию”.

3.3.8 Главный сценарий: позиция приходит позже газа

Соберём всё вместе на примере шахтёра M1 со сценарием из `Mock_source.Default`:

1. $t = 10s$ — газовый пакет M1 с $CO = 120$ ppm (Critical). `st.position = None`. Эмитим `Gas_alert(level=Critical, ppm=120, position=None)`. `active[Gas_CO]` запомнила это.
2. $t = 15s$ — первый RSSI-пакет M1 с reading’ами от B1, B2, B3. `Position_from_raw.st.position` была `None`, `single_beacon_position` даёт координаты B1 (сильнейший reading). `st.position` обновлена. `refresh_alerts_for_new_position` проходит по `active`: видит `Gas_CO` с `position=None`, `position` обновилась → эмитим `Retract(old alert, position=None) + Data(new alert, position=B1’s coords)`.
3. $t = 20s$ — ещё один газовый пакет $CO = 119$ ppm. Critical тот же, ppm в пределах 20% (119 vs 120), `position` та же. Все три проверки false — ничего не эмитим.
4. $t = 60s$ — первое RSSI-окно [0,60) закрывается. M1 имел в нём reading’и от B1 и B2 (как минимум). `median_rssi` эмитит `location` с `loc_position` равной интерполяции B1-B2. `Position_from_window` обновляет `st.position` — безусловно (точная позиция важнее грубой). `refresh_alerts_for_new_position` снова: `Retract` старого алерта (с грубой позицией B1) + `Data` с новой позицией.

После этого алерт *остаётся живым* с актуальной позицией. Если координаты дальше не меняются (sliding окна выдают ту же интерполяцию) — больше ничего не эмитится. Если меняются — ещё один `retract + emit`. Если CO падает ниже 50 ppm — `retract + Gas_resolved`.

Что видит диспетчер. Sink через `Pipe.materialize` сворачивает `retract`’ы. На дашборде в любой момент видна одна запись на (M1, CO) с *текущим* ppm и *актуальной* позицией. Промежуточные `retract`’ы под капотом обеспечивают что эта запись правильная — но на экран попадает только финальная картина. Это и есть ценность `retract`-семантики — диспетчер видит правду, не флудя истории.

На этом разбор трёх пайплайнов закончен. В следующем разделе обобщаем retract как *сквозной механизм* проходящий через все три, и объясняем как sink его материализует.

4 Retract как сквозной механизм

В трёх пайплайнах раздела 3 retract упоминался четыре раза в разных контекстах: автоматически от `window_agg_keyed` при опоздавших пакетах в локации; вручную в `gas_alerts` при обновлении уровня, ppm или позиции; `Gas_resolved` как явный «retract плюс новость» когда тревога снята; и материализация в sink через `Pipe.materialize`. Это не четыре разных приёма — это одна *семантическая модель*, проходящая через всю архитектуру. В этом разделе мы её обобщаем.

4.1 Что такое retract семантически

Поток событий в miniFlink имеет три конструктора:

```
type 'a t =
  | Data      of 'a * Time.t
  | Retract   of 'a * Time.t
  | Watermark of Time.t
```

Самый прямой способ читать `Data v t` — «в момент t верно что v ». Соответственно `Retract v t` — «в момент t больше не верно что v ». Это не «отмена события», а *отрицание ранее эмитированного значения*.

Получается, что поток описывает не последовательность независимых сообщений, а *меняющуюся во времени таблицу*. `Data` добавляет или обновляет строку, `Retract` помечает строку недействительной. Если в момент t_1 был `Data v1`, а в момент $t_2 > t_1$ пришёл `Retract v1`, то для downstream “состояние $v1$ ” существовало в интервале $[t_1, t_2)$ и не существует после.

Эта модель встречается в литературе под названиями *retraction streams*, *changelog streams*, *CDC (change data capture) streams*. В Flink Table API она формализована как `retract stream` в противоположность `append-only stream` и `upsert stream`.

4.2 Три места эмиссии в ex07

В нашем сервисе retract эмитится в трёх разных местах с разной *причиной*:

Window_agg_keyed: автоматически при опоздавших пакетах. Опоздавший пакет, попадающий в уже закрытое окно в пределах `allowed_lateness`, заставляет оператор *перезакрыть* окно, пересчитать агрегат и эмитнуть `Retract` прежнего результата плюс `Data` нового. Пользователь пишет

```
window_agg_keyed ~by:... ~allowed_lateness:(seconds 60)
  (sliding ...) Agg.(...)
```

и получает retract-богатый поток без явных усилий. Цена retract’а здесь — цена корректности: либо мы получаем последовательные `Data/Retract/Data` с консистентным смыслом, либо игнорим опоздавших и теряем данные.

Gas_alerts: вручную при обновлении состояния. Газовый пайплайн эмитирует retract в трёх независимых случаях — смена уровня опасности (`Warning` ↔ `Critical`), изменение ppm

более чем на 20%, обновление позиции шахтёра. Это *не* “окно переоткрылось” — это пользовательская бизнес-логика, которая сама решает что предыдущий алерт *устарел* и должен быть заменён актуальным. Семантически тот же retract, но порождаемый из доменной логики, а не из оператора.

Gas_resolved: явный конструктор «алерт снят».

```
type gas_alert =  
  | Gas_alert of {...}  
  | Gas_resolved of { gr_lamp; gr_ts; gr_gas }
```

Когда газ возвращается в норму, мы эмитим **Retract** последнего живого **Gas_alert** плюс **Data (Gas_resolved ...)** — *два* события одновременно. Можно было бы обойтись одним **Retract**’ом, без **Gas_resolved**. Но тогда диспетчер получал бы *неявное* обновление: «алерт пропал из таблицы». **Gas_resolved** же — *явное* событие «больше не тревога», которое можно показать в журнале действий: “18:42, МЗ, CO2 вернулся в норму”. Это улучшает observability системы за счёт небольшой избыточности.

4.3 Sink: материализация через Pipe.materialize

Retract-богатый поток подходит для *передачи между операторами* или *транзита* в downstream-систему. Но *диспетчерскому дашборду* нужна не история retract’ов, а *актуальная картина* — что прямо сейчас активно. Чтобы свернуть retract-богатый поток в текущее состояние, библиотека даёт оператор **Pipe.materialize**.

```
let publish_gas_alerts events =  
  let materialized =  
    events |> Pipe.materialize ~by:(fun a _t ->  
      match a with  
      | Gas_alert ga      -> 'Alert (ga.ga_lamp, ga.ga_gas)  
      | Gas_resolved gr -> 'Resolved (gr.gr_lamp, gr.gr_gas)) in  
  let active = Hashtbl.create 8 in  
  List.iter (fun (key, alert) ->  
    match key, alert with  
    | 'Alert (lamp, gas), Gas_alert _ ->  
      Hashtbl.replace active (lamp, gas) alert  
    | 'Resolved (lamp, gas), Gas_resolved _ ->  
      Hashtbl.remove active (lamp, gas)  
    | _ -> (()) materialized;  
    (* print whatever remains in 'active' *)
```

materialize ~by группирует события по ключу (в нашем случае — пара “шахтёр, газ”), и для каждого ключа оставляет *последнее* актуальное значение: последний **Data** перевешивает все предыдущие **Retract**’ы и **Data**’ы. На дашборд попадает *одна строчка* на пару (M1, CO), независимо от того, сколько обновлений было под капотом.

Тот же приём в локации:

```
publish_locations ~beacon_coords stream
```

материализует по (шахтёр, конец окна) и показывает только финальные значения окон. Опоздавший пакет, заставивший окно переоткрыться, под капотом был **Retract+Data**, на экране — просто обновлённое значение.

4.4 Альтернатива: `append-only stream`

Можно было бы построить ту же систему *без* `retract`-ов — эмитируя только `Data`, как `KafkaTopic` с уникальными сообщениями. Получился бы *append-only* поток событий, и `downstream` сам бы разбирался, какая запись актуальна.

Это работает в некоторых случаях, но имеет два недостатка для нашего сервиса:

Сложность на каждом потребителе. Дашборд диспетчера — один из потребителей газового потока. Но потенциальных потребителей много: журнал действий, статистический агрегатор за смену, интеграция с системой эвакуации. Если `retract`-логика *не* в библиотеке, она будет на каждом потребителе — несовместимые реализации “какая запись актуальна” дадут разные картины в разных подсистемах.

Невозможность `retract`-а в общем случае. `Append-only` поток не имеет способа сказать “прежнее значение больше не актуально”. Только эмитировать новое значение и надеяться что потребитель его интерпретирует как замену. Для большинства случаев это нормально, но для `Gas_resolved` это означало бы что `diff` между “тревога” и “нет тревоги” пропадал бы в шуме других событий.

`Retract` как первоклассное событие смещает эту работу из `downstream` в библиотеку. Стоит того, когда потребителей много или семантика важна (нашему диспетчеру обе вещи важны).

4.5 Цена `retract`-а

`Retract` не бесплатен. За полную часовую симуляцию `Large_mine` (949K `RSSI` пакетов, 5% `gas`-сценариев) `median_rssi` эмитит около 180 000 `Retract`-ов поверх результатов окон — примерно *один retract на каждые пять закрытых окон*. Это и есть «цена опаздавших пакетов»: 3% из них попадают в `allowed_lateness`-зону, и для каждого окна переоткрывается с `retract+emit`.

В газовом пайплайне на сценарии `Default` (6 шахтёров, 6 минут симуляции) видим 194 событий газовых алертов и 95 `retract`-ов — то есть почти *половина* газовых событий является `retract`-ами. Это много в относительном выражении, но абсолютно — меньше 100 за 6 минут, не нагрузка.

В большой шахте при типичном проценте `gas`-аномалий (5% шахтёров) тренд сохраняется: газовых событий мало в абсолюте, `retract`-ы дают 50% от их числа. Это 5–10 `retract`-ов в секунду пик — ничто на фоне 1000+ `RSSI`-событий в секунду.

Размер сети. В прода-deployment’e, где `sink` публикует в `Kafka`, каждый `retract` — отдельное сообщение в топике. Размер сетевого трафика растёт пропорционально количеству `retract`-ов. Это закладывается в `capacity planning`, но обычно несущественно — `ev/s` от `retract`-ов значительно ниже основного трафика.

Сложность потребителя. Потребитель должен понимать `Mf_event.Retract` и применять его правильно. В рамках `miniFlink` это даёт `Pipe.materialize`, на стороне внешних систем (`Kafka consumer`) — надо реализовывать вручную или полагаться на формат как `Kafka Streams` с явной `retract`-семантикой.

4.6 Когда `retract` не нужен

`Retract` — мощный инструмент, но не везде уместен.

Append-only поток нормален когда:

- У потока нет окон с late-семантикой — например, *audit log*: каждое действие шахтёра записывается, *retract* здесь *вреден* (нельзя “отменить” факт нажатия SOS, даже если оказалось ложным; правильно — эмитнуть второе событие “ложный SOS”).
- Downstream идемпотентен по природе — например, отправка push-уведомлений с уникальными ID. Дубль безвреден.
- Семантика “последнее значение” нам не нужна — мы хотим видеть *все* события (журнал).

В `ex07 connectivity_alerts` *не использует* `retract`: алерт “No_motion на M1 в 12:34” — это факт. Если шахтёр потом зашевелился — эмитим *новое* событие “Motion_resumed” (не реализовано в текущем коде, но было бы естественно), не `retract`’им предыдущий алерт.

Решение «`retract` или `append-only`» — доменное. Сервис может содержать оба типа потоков одновременно: газовые алерты — `retract`-богатые, журнал диагностики — `append-only`. Библиотека позволяет и то, и другое; разработчик выбирает по сути данных.

В следующем разделе посмотрим на производительность всех трёх пайплайнов и на то, как направленные оптимизации (миграция окон на `Hashtbl`, параллелизация через `fan_out`) дали суммарно $\sim 10\times$ ускорение, ни разу не тронув бизнес-логику.

5 Производительность

Этот раздел — история двух направленных оптимизаций, поднявших `median_rssi` с исходных 19K событий в секунду на одном ядре до 184K событий в секунду на параллельной обработке. Каждая оптимизация подтверждена бенчмарком, и ни одна не потребовала изменений в бизнес-логике пайплайна.

Все измерения сделаны на машине автора отладки (Intel Core i7-8700 с шестью физическими и двенадцатью логическими ядрами), OCaml 5.1.1, полная конфигурация `Mock_source.Large_mine` (949K RSSI-пакетов, 5% шахтёров с газовыми событиями, час event-time-симуляции). Каждый бенчмарк — один прогрев + 3–4 измерения, отчётная цифра — медиана.

5.1 Что меряем

В репозитории три бенчмарка, по-разному отвечающих на вопрос “насколько быстро”.

bench_ex07. Sequential-прогон полных пайплайнов на `Large_mine`. Меряет *собственно* стоимость бизнес-логики — сколько event-time-времени укладывается в одну секунду wall-clock. Если `ev/s` превышает реальную нагрузку (270 RSSI `ev/s` + 400 газовых на полной шахте), сервис укладывается на одном ядре.

bench_scaling. Синтетическая нагрузка через `Parallel.run_parallel_simple` с 1, 2, 4, 6, 8, 12 воркерами. Меряет *параллельную масштабируемость* библиотеки вне связи с конкретным пайплайном — то есть отвечает на вопрос “работает ли `Domain.spawn` как ожидается на этой машине”.

bench_ex07_parallel. Тот же `Large_mine`, но обёрнутый в `fan_out: connectivity_alerts` и `median_rssi` прогоняются отдельно с 1, 2, 4, 6, 8, 12 воркерами. Меряет *параллельную производительность конкретных* пайплайнов в нагрузке близкой к проде.

Дальше идём по направленным оптимизациям. Каждая описывает что было до, что сделали, и что получили.

5.2 Sequential baseline и переход на OCaml 5

Исходные числа (OCaml 4.14 на Xeon, ранние сессии) для `median_rssi` на полной `Large_mine`: около 19K ev/s. `connectivity_alerts`: около 362K ev/s. Газового пайплайна тогда не было.

Сам по себе переход с OCaml 4.14 на OCaml 5.1.1 sequential производительность *практически не меняет* — new GC и runtime дают единицы процентов на single-thread workload (что ожидаемо: рантайм 5-го поколения оптимизирован под параллельность, не под скорость одного потока).

Зачем тогда переходить. Чтобы получить настоящую параллельность через `Domain.spawn`. На OCaml 4.14 многопоточность работает через POSIX-поток под global runtime lock'ом: верхний предел масштабирования $\sim 2.87\times$ независимо от числа ядер. На OCaml 5 этого ограничения нет.

Подтверждено бенчмарком `bench_scaling`: на i7-8700 с двенадцатью логическими ядрами синтетическая нагрузка ускоряется в 5.71 раз на двенадцати воркерах относительно одного. На OCaml 4 на той же машине верхний предел был бы $\sim 2.5\times$. Цифры сохранены в README репозитория.

5.3 Hashtbl миграция: 1.63x на одном ядре

Первая направленная оптимизация была не про параллельность — про размер аллокаций. Прогон `bench_ex07` на ранней версии `median_rssi` показал: 84,4 секунды wall-clock, 70 ГБ аллокаций за прогон, GC-паузы съедают треть времени.

Внутри `window_agg_keyed` state окна был реализован как `(key, list)` в списке списков: для каждого активного окна *все значения* держались в OCaml list, и при закрытии окна проходили через `List.sort` для медианы. На полной шахте за час симуляции это давало 70 ГБ аллоцированных Cons-ячеек.

Замена сделана *внутри библиотеки* — `window_agg_keyed` теперь использует `Hashtbl` для индексации окон по ключу шахтёра, и для каждого окна `Buffer` для накопления значений вместо списка. `Pipelines.median_rssi` и `ex07` остались *без изменений* — API не поменялся, изменилось внутреннее представление.

Результат: 51,8 секунды (вместо 84,4 — **1.63x ускорение**), 27 ГБ аллокаций (вместо 70 — **минус 61%**). Throughput `median_rssi`: 19K $\rightarrow$ 44K ev/s на одном ядре.

Уроки этого эпизода.

- Узкое место найдено не догадкой, а измерением (allocated bytes из `Gc.stat`). Без бенчмарка с метриками памяти могли бы “оптимизировать” не то.
- Оптимизация *внутри* библиотеки не задела пайплайны. Это и есть архитектурное обещание оператора как абстракции: поменять реализацию можно, не трогая клиентов.
- Никаких ухищрений в идиоматичности OCaml: `Hashtbl` — обычная стандартная библиотека, `Buffer` — тоже. Простая правильная структура данных дала 1.63x безо всякой магии.

5.4 Параллелизация median_rssi через fan_out

После Hashtbl-миграции естественное следующее направление — параллелизация. Пайплайн `Pipelines.median_rssi` остался `sequential`; параллельная обёртка строится *над* ним через `Parallel.run_parallel_simple`, разделяющий поток по `lamp` между N воркерами:

```
Parallel.run_parallel_simple
  ~workers:8
  ~capacity:4096
  ~key_of:(fun (p : packet) -> p.lamp)
  ~pipeline:Pipelines.median_rssi
  ~source:(Src.read ())
  ~sink:(fun _loc -> Atomic.incr n)
  ()
```

`median_rssi` здесь — та же функция, которую использует `sequential`-вариант. Изменился *только* способ её запуска.

Результаты `bench_ex07_parallel.median_rssi` на i7-8700:

воркеров	время	ev/s	speedup
sequential	22,25 с	44K	1.00×
1	22,22 с	44K	1.00×
2	12,07 с	81K	1.84×
4	6,92 с	142K	3.22×
6	6,36 с	155K	3.50×
8	5,33 с	184K	4.17×
12	5,93 с	166K	3.75×

Пик на 8 воркерах — 184K ev/s, 4.17× от `sequential`. На 12 воркерах слабая регрессия — это `hyperthreading` на `CPU-bound` с большой GC-нагрузкой не помогает (НТ эффективен когда потоки часто ждут памяти, а у нас потоки заняты CPU-работой).

Почему именно 4.17х, не 8х. На полные 8 ядер не масштабируется по нескольким причинам. Главная — `per-domain GC` в OCaml 5 локализован *в пределах domain'a*, но `major GC` по-прежнему останавливает все домены. На GC-нагруженной `workload` (наши окна аллоцируют по 27 ГБ за прогон даже после Hashtbl-миграции) `major GC` паузы становятся общим `bottleneck`-ом. Это нормальное поведение OCaml 5; для дальнейшего ускорения пришлось бы снижать аллокации.

5.5 connectivity_alerts: коленом в dispatcher

Тот же бенчмарк применили к `connectivity_alerts`. Результат заметно другой:

воркеров	время	ev/s	speedup
sequential	1,14 с	859K	1.00×
1	1,21 с	810K	0.94×
2	0,70 с	1.41M	1.64×
4	0,43 с	2.30M	2.68×
6	0,59 с	1.66M	1.94×
8	1,11 с	888K	1.03×
12	1,32 с	744K	0.87×

Пик на 4 воркерах — 2.68×, потом резкая *деградация* до 0.87× на 12. На 12 воркерах параллельная версия *медленнее* `sequential`.

Что случилось. `Sequential connectivity_alerts` очень быстрый — 859K ev/s означает примерно 1,2 микросекунды на одно событие (FSM-обработка простая, без аллокаций окон). `Channel.push/Channel.pop` в воркер добавляют порядка 100–200 наносекунд — это 10–20% оверхеда на каждое событие. На 4 воркерах работа распределяется и оверхед себя оправдывает. На 8+ воркерах *dispatcher single-thread* — тот единственный поток, который читает source-stream и распределяет события по каналам воркеров — не успевает кормить каналы. Параллельность упирается не в воркеров, а в раздатчика.

Это *не баг библиотеки*, а свойство конкретной нагрузки: очень быстрый sequential pipeline на простой обработке плохо масштабируется через single-dispatcher fan-out. Решение — multi-dispatcher (несколько потоков-раздатчиков, каждый кормит часть воркеров). Сделано не было: в нашем сервисе фактическая нагрузка `connectivity_alerts` на полной шахте — 270 ev/s, и пик 2.68x избыточен на пять порядков (859K vs 270). Оптимизировать ещё дальше нет смысла.

Урок. Узкое место параллельности не всегда там, где ожидается. `median_rssi` с медленным sequential масштабируется хорошо потому что у dispatcher’a *есть время* кормить каналы. `connectivity_alerts` с быстрым sequential упирается в dispatcher сразу. Это априори неочевидно — обнаружено только бенчмарком.

5.6 Суммарный эффект

Накопленное ускорение `median_rssi`:

исходный sequential (OCaml 4)	19K ev/s
после Hashtbl-миграции (OCaml 4)	36K ev/s
sequential на i7-8700 OCaml 5	44K ev/s
parallel-8 на i7-8700 OCaml 5	184K ev/s

От 19K до 184K — **около 9,7 раз**. Каждый шаг *направленный*: бенчмарк показал bottleneck, оптимизация адресовала именно его, бенчмарк после оптимизации подтвердил ускорение. Никакой “general performance work”.

Реальная нагрузка на полной шахте — 270 RSSI ev/s от 4096 шахтёров. У нас **запас 680x**. Это *не* избыточно для системы безопасности: пиковые моменты (несколько горящих участков одновременно, импульсные помехи от шахтной техники, перестроение большого сегмента mesh когда габаритная техника перекрывает радиолинки между узлами, перезапуск пограничного ВОЛС-коммутатора) дают взрывы в десятки тысяч событий в секунду на короткий период. Сервис должен в эти моменты не терять алерты, а это требует многократного запаса по throughput.

5.7 Что не оптимизируем намеренно

Газовый пайплайн. Бенчмарк параллельной версии `gas_alerts` в репозитории есть как `bench_ex07_parallel`, но измерения именно газовой части на полной `Large_mine` не сделаны — газ *редок* (5% шахтёров), и абсолютная нагрузка маленькая (десятки событий в секунду на пиках). Оптимизировать газовый пайплайн без необходимости — waste of time.

Стационарный run-loop. Сейчас прогон бенчмарка — “прочитать всё, обработать, выйти”. В реальной шахте сервис работает *бесконечно*, и важна не throughput на закрытом датасете, а stability на стримящемся. Длительный run-loop с правильной семантикой shutdown, retry на упавших воркерах, backpressure от sink’a к источнику — отдельная тема, в ex07 не покрыта.

Trilateration с GPU. Чисто гипотетически: если бы геометрия шахты была не тоннелем, а открытым складом, и нужна трилатерация на сотнях шахтёров одновременно — имело бы смысл выгрузить вычисления на GPU. В нашей задаче это не нужно (интерполяция между двумя биконами — $O(1)$ на шахтёра, 5 шахтёров в окне) и было бы over-engineering.

В следующем разделе подводим итоги: что в ex07 было сделано сознательно, что отложено и почему, что должно быть в полной прода-системе.

6 Выводы

6.1 Что построено

Сервис для подземной шахты, обрабатывающий два независимых потока телеметрии и выдающий три семейства алертов: диагностика состояния шахтёра, локация по маякам связи, газовые алерты с обогащением координатами. Корректно работает на потоке с дублями, опоздавшими пакетами, переменными частотами источников. Под нагрузкой большой шахты (950K RSSI-пакетов в час, 4096 шахтёров) выдерживает порядок 200K событий в секунду на одной машине.

Объём кода — порядка 700 строк бизнес-логики поверх библиотеки miniFlink. Из них примерно треть — доменные типы (`packet`, `alert`, `location`, `gas_packet`, `gas_alert`) и пороги. Остальное — три пайплайна и тонкие обвязки источника и sink'a.

Архитектурно ничего эксклюзивного в шахте нет — любая задача “принимает телеметрию от IoT-устройств, реагирует на падение связи и аномальные показания, обогащает алерты контекстом” имела бы ту же структуру. Шахта здесь служит конкретным сценарием с понятными требованиями.

6.2 Что отложено намеренно и зачем нужно для прода

Текущий ex07 — демо-сервис. Несколько вещей нужны для реального развёртывания, и сознательно не сделаны в примере:

Реальные источник и sink. `Mock_source` генерирует поток из конфигурации, `Mock_sink` печатает в stdout. В производстве нужны `Kafka_source.read` и `Kafka_sink.publish` или их эквиваленты для конкретного брокера. miniFlink включает примеры таких источников (`ex06_topology` использует канальный источник/sink, но не Kafka напрямую — это требует внешней зависимости и deployment-специфики, оставлено для конкретного проекта).

Персистентное state. Сейчас весь state (`Last_seen` шахтёров, окна локации, активные газовые алерты) живёт в памяти. При рестарте сервиса — теряется, заново накапливается из приходящих пакетов. Для шахтной системы безопасности это *неприемлемо*: если активный газовый алерт исчез из state из-за рестарта на сервере, диспетчер увидит мнимое снятие тревоги. С тех пор как этот раздел был написан, в miniFlink появилась *ортогональная* модель персистентности: каждый stateful-оператор работает одинаково с durability и без неё, режим выбирается снаружи пайплайна через ambient-контекст (`with_context(durable backend)`), а сериализация состояния идёт по умолчанию и не попадает в код оператора. Это снимает описанное ограничение на уровне библиотеки — ex07-пайплайны становятся durable простым оборачиванием, без единого изменения доменной логики; их перевод на durable-режим в рамках production-сервиса (см. ниже) остаётся прикладной задачей, но уже не требует переписывания операторов. RocksDB-бэкенд (`State_backend_rocksdb`) служит durable-хранилищем.

Checkpoint и recovery. Связано с персистентным state — способ восстановить exactly-once-семантику после падения. В Flink это `Distributed Snapshot`, в miniFlink — модуль `Checkpoint` с примером в `ex06_topology`. Включение checkpoint в ex07-пайплайны — задача отдельной работы, требует обдумать политики (как часто checkpoint, куда сохранять, что делать при разногласии checkpoint’a и источника).

Multi-dispatcher fan_out. В разделе 5 показали что `connectivity_alerts` упирается в single-thread dispatcher на 8+ воркерах. Lib-уровневое решение — несколько параллельных dispatcher’ов, каждый кормит часть воркеров. В нашей конкретной нагрузке (270 ev/s) это не нужно, но для систем с гораздо более быстрым sequential-pipeline (например, обработка сетевых пакетов в Tbps-нагрузке) станет существенным.

Калибровка RSSI на месте. Формула $-40 - 20 \log_{10}(d)$ параметризована для свободного пространства. В реальном тоннеле коэффициент поглощения зависит от породы и оборудования, и калибруется эмпирически на каждом горизонте при вводе шахты в эксплуатацию (обходим со специальным meter’ом, замеряем RSSI на известных расстояниях, строим регрессию). У нас в коде — константа.

Газовый бенчмарк на полной шахте. Параллельная версия `gas_alerts` в репозитории есть, но измерения именно её на полной `Large_mine` не сделаны. Газовых событий объективно мало (5% шахтёров с превышениями), но stress-test с пиком “все газовые сенсоры одновременно показывают критическое значение” было бы полезно для capacity planning.

6.3 Что не отложено, а просто не нужно

Трилатерация и GPU. Геометрия тоннеля делает трилатерацию неприменимой; линейной интерполяции между двумя биконами достаточно для целевой точности (одна длина пролёта). GPU-ускорение задачи, которая занимает $O(1)$ на одного шахтёра — over-engineering.

Машинное обучение для предсказания газов. Соблазн “обучить модель на исторических данных предсказывать аварии за час вперёд” возникает у любого продукт-менеджера. Не вписывается в эту работу по двум причинам: (1) это другой класс задачи (predictive analytics поверх stream’a, а не stream processing per se), (2) обоснованность предсказаний газовой аварии за час — отдельная большая дискуссия с шахтёрами и геологами, не делается “просто прицепить ML”.

Веб-UI для диспетчерского пульта. ex07 не включает front-end. Диспетчерский пульт — отдельный проект на отдельном стеке (React-приложение, web-socket к sink-серверу, рендеринг шахты на канвасе). Stream processing service выдаёт *данные*; интерфейс к ним — не его дело.

6.4 Когда брать stream processing подход

Stream processing — не серебряная пуля. У него есть конкретная область применимости, и за её пределами он избыточно сложный.

Когда оправдан:

- Данные приходят с *временем* (event-time), и задержки в сети различных для разных событий.

- Нужна реакция на *молчание* (timeout-семантика): “алерт если события нет N минут”. REST API на это плохо приспособлен.
- Окна с *late events*: данные за окно [60, 120) могут прийти в момент 145. Если терять — неверный результат.
- Несколько источников с *разными частотами*, и нужно их корректно соединить.
- State *per-key*, который накапливается во времени и влияет на решения по этому ключу.

ex07 одновременно использует все пять — классическая зона применимости stream processing.

Когда не оправдан:

- Данные приходят равномерно, нет позднего прихода, нет требования к event-time. *Batch ETL* раз в N минут с обычным SQL — проще.
- Каждый запрос обрабатывается независимо, без состояния по ключу и без окон. REST API + кеш — проще.
- Реакция нужна на *один* тип события без объединения с другими источниками. Webhook + правило в обработчике — проще.
- Объём данных небольшой, и допустима задержка в минуты. Cron job с обычным скриптом — проще.

Простота важна сама по себе. Stream processing требует ментальной модели event-time, watermark’ов, retract’ов, state’ов с TTL — немалый baggage для команды. Если задача его не требует, прибегать к нему ради “архитектурной правильности” — ошибка.

6.5 Финальная мысль

ex07 показывает что stream processing подход даёт *качественно другой* результат на задаче которая в него попадает: 700 строк бизнес-логики дают корректный сервис, который не падает на опоздавших пакетах, не двойит алерты на дублях, обновляет существующие алерты при поступлении новой информации, и масштабируется параллельно когда понадобится. Тот же сервис, написанный “в лоб” на голом OCaml + Unix-таймерах + хеш-таблицами, занял бы существенно больше кода и неминуемо имел бы тонкие баги в обработке late events, дублей и shutdown’a.

Это не аргумент за *любую* stream processing библиотеку и не за miniFlink конкретно. Это аргумент за то, чтобы *выбирать инструмент по форме задачи*, и понимать когда задача попадает в зону “нужны event-time, окна, retract, per-key state”. ex07 — рабочий пример того, как такое попадание выглядит.