

miniFlink ex07

Сервис локации и газовых алертов для подземной шахты:
пошаговый разбор архитектуры

Abstract

ex07 — самый большой пример в репозитории miniFlink. Он строит сервис для подземной угольной шахты, который из двух независимых потоков (пакеты от фонарей и пакеты от газовых датчиков) выдаёт три типа выходов: алерты состояния шахтёра, локацию по маякам связи и обогащённые координатами газовые алерты. Под капотом используется почти весь арсенал библиотеки: скользящие окна с `allowed_lateness`, `group_by`, FSM через `process_keyed`, объединение потоков с выравниванием `watermark`, `retract`-семантика для обновлений.

Эта статья — подробный разбор того, *зачем* каждое решение принято таким, как оно принято: какие альтернативы рассматривались, почему отброшены, что бы случилось при наивной реализации. Цель — дать инженеру, выбирающему stream processing, конкретный материал для оценки, а контрибьютору — понимание design-rationale.

Contents

1	Задача	1
1.1	Что должен делать сервис	2
1.2	Что в этой задаче сложного	2
1.3	Почему через библиотеку, а не «просто кодом»	3
1.4	Что есть готового в miniFlink	4
1.5	Что увидим дальше	5
2	Входы	5
2.1	Два независимых потока, а не один	5
2.2	Структура RSSI-пакета	6
2.3	Структура газового пакета	6
2.4	Дрожание канала	7
2.5	Large_mine: масштабная конфигурация	7
3	Три пайплайна	8
4	Retract как сквозной механизм	8
5	Производительность	8
6	Выводы	8

1 Задача

Представьте себе подземную угольную шахту: километры тоннелей на нескольких горизонтах, в среднем по сорок-сто шахтёров на смену, у каждого фонарь, который раз в пятнадцать

секунд шлёт радиопакет с показаниями нескольких ближайших маяков связи, а раз в десять секунд — отдельный пакет с показаниями газовых сенсоров. Эти пакеты летят в диспетчерскую через смесь UDP-радио и LTE-шлюзов, доходят с задержками, иногда дублируются, иногда теряются.

В диспетчерской на стене висит экран с картой шахты и состоянием смены: где находится каждый шахтёр, у кого тревога по газу, кто прижал кнопку SOS, у кого вот-вот сядет батарейка фонаря. Этот экран обслуживает наш сервис.

1.1 Что должен делать сервис

Если разложить требования *диспетчера* на конкретные пайплайны, получается три независимых подсистемы:

Контроль состояния шахтёра. Из RSSI-пакета извлекаем не показания маяков (это работа другой подсистемы), а *косвенные факты*: пакет вообще пришёл, в нём были показания, фонарь двигался, напряжение батареи в норме. По каждому из этих фактов держим независимый таймер и эмитим соответствующий алерт когда таймер перевалил порог: “не было пакетов больше двух минут”, “пакеты идут, но маяков не слышит больше пяти”, “не двигался дольше порога”, “батарея ниже 3,5 В с дребезгом по гистерезису”. Плюс импульс SOS (нажатая кнопка) — мгновенный без таймера.

Локация по маякам. Для каждого шахтёра в скользящем 60-секундном окне с шагом 5 секунд берём топ-2 маяков с самой сильной медианной RSSI и из них приближённо вычисляем координаты шахтёра через интерполяцию между двумя маяками пропорционально расстоянию. Окно скользит каждые 5 секунд, поэтому диспетчерский экран обновляется не реже чем раз в 5 с; при опаздавшем пакете окно *переоткрывается* и эмитит **Retract** старого значения с последующим обновлённым **Data** — так картинка остаётся консистентной.

Газовые алерты с обогащением координатами. Газовый пакет приходит *отдельно* и сам по себе не несёт ID маяков или позиции. Когда газ превышает порог — алерт идёт немедленно (безопасность важнее красоты), но без координат, если их ещё не было. Как только локация для этого шахтёра становится известна (хотя бы по одному маяку), алерт автоматически *обновляется*: старая версия без координат retract’ится, новая с координатами эмитится. То же самое при смене уровня опасности (Warning → Critical) или существенном изменении ppm. Когда газ возвращается в норму — алерт снимается через **Gas_resolved**.

Эти три подсистемы независимы по бизнес-логике, но обмениваются данными: газовый пайплайн *потребляет* результат пайплайна локации, чтобы обогатить свои алерты координатами.

1.2 Что в этой задаче сложного

Если бы это была учебная задача из курса по базам данных, её можно было бы решить за полчаса: батчевый ETL раз в минуту, JOIN по шахтёру, отрисовка в дашборд. Но в реальной шахте такое решение *бесполезно*, и причин этому несколько.

Время событий не равно времени поступления. Пакет от шахтёра M1 с временной меткой **t=88s** может прийти в диспетчерскую в момент **t=210s**: UDP в шахте теряет пакеты, LTE-шлюз делает повторные попытки, на агрегаторе очереди. Если мы будем считать алерты по wall-clock времени поступления, то получим “M1 не двигался последние 2 минуты” в момент когда M1 уже давно дома — его пакет о движении просто опаздывает по дороге. Сервис должен работать по *event-time* (времени самого события), а не по wall-clock.

Идемпотентность. Тот же UDP-механизм даёт дубликаты: пакет может прийти дважды, потому что шлюз ретранслировал его при сомнениях. Если мы будем считать тревогу по второму дублию “независимо”, получим *два* алерта SOS на одно нажатие кнопки. Диспетчер не должен видеть фантомных тревог.

Опоздавшие пакеты ломают окна. Окно [60s, 120s) закрылось в 120с, и пайплайн эмитнул финальное top-2 маяков. Но в 145с пришёл опоздавший пакет с `ts=90s` — он *принадлежит* уже закрытому окну. Нужно либо его выбросить (теряем данные), либо переоткрыть окно, пересчитать агрегат и эмитнуть новое значение, помечая старое как недействительное. Второе правильно для диспетчера; первое было бы дешевле, но даёт непредсказуемый дашборд (на одной и той же временной метке могут быть разные значения в разные моменты wall-clock).

Газовый алерт без координат лучше чем нет алерта. Газ начинает выделяться *раньше* чем шахтёр успевает прийти под маяк — особенно в забое, где маяки ставят редко. Если ждать координат прежде чем эмитить тревогу о 120 ppm CO, можно потерять минуты на ожидании. Алерт идёт сразу. Но как только координаты появляются — они должны *подтянуться* к уже существующей тревоге, не порождая дубль и не давая диспетчеру повод закрыть старый алерт и открыть новый вручную.

Объём. Шахта на сорок шахтёров — мелочь. Реальные большие шахты в Кузбассе или Караганде имеют до четырёх тысяч работников в смену. RSSI-пакетов от такой шахты получается порядка 270 ev/s, газовых — ещё 400 ev/s. Это немного по меркам стримов, но *пайплайн должен держать нагрузку с запасом*: пиковые моменты (несколько горящих участков, грозовая помеха в радио, перезапуск шлюза) дают взрывы в десятки тысяч событий в секунду на короткий период. Сервис не должен в эти моменты терять алерты.

1.3 Почему через библиотеку, а не «просто кодом»

Каждый описанный выше пункт сложности *можно* решить вручную: структуры данных в OCamI есть, потоки тоже, таймеры в Unix доступны, голый код пишется. Но есть несколько мест, где «можно вручную» означает *можно сделать так, что в проде это работать не будет*. miniFlink в каждом из них берёт на себя самую тонкую часть.

Event-time и watermark. Без явной модели событийного времени любая обработка с окнами и таймерами скатывается к *wall-clock*: «считаем средний RSSI за последнюю минуту по часам в нашем сервере». В шахте это даёт явные ошибки: пакет с `ts=88s` физически пришёл к сервису в 210s (UDP + LTE-retry + очередь), и попадает в окно для текущей минуты, искажая её. miniFlink требует чтобы в потоке шли явные **Watermark**-события и каждый оператор окон работал по ним. Голый аналог пришлось бы писать самому, причём правильно: проверять ordering, перепроверять для каждого нового пайплайна, тестировать для каждого варианта late-семантики.

Retract как первоклассное событие. `allowed_lateness` в `window_agg_keyed` даёт нам *автоматический* retract: опоздавший пакет, который попадает в уже закрытое окно (в пределах `allowed_lateness`), вызывает **пересчёт** окна и эмиссию **Retract** старого значения плюс новый **Data**. Голый код имеет два пути: либо просто дропать опоздавшие пакеты (теряем данные ради простоты), либо пересчитывать без retract’ов (диспетчер видит мигание значений на дашборде, потому что окна *переоткрываются* молча). Третий правильный путь — сделать retract как явное событие — это и есть то, что библиотека реализует один раз и для всех пайплайнов.

Дедупликация по бизнес-правилу. UDP-шлюз в шахте ретранслирует пакеты при сомнениях — получаем дубли. Наивное “HashSet по сериализованным байтам” сломается мгновенно: шлюз обогащает пакет полем `received_at`, и идентичные по смыслу пакеты различаются на байтовом уровне. `Pipe.dedup` берёт правило вида `p.lamp ^ string_of_int p.ts` — ключевое поле бизнеса, не байты транспортного протокола.

State per-key + automatic cleanup. `Pipe.process_keyed` держит state per-key (по шахтёру), вызывает наш обработчик, поддерживает self-timer’ы для timeout- семантики (alert после двух минут тишины). На четырёх тысячах шахтёров голый код потребует свой `Hashtbl<lamp, state>`, ручную регистрацию таймеров, ручную очистку state после конца смены. Каждое из этого — источник багов; например, мы могли бы накопить state шахтёров прошлой смены и тек уть память. Библиотека предоставляет TTL-state из коробки.

Channel с backpressure. Грозовая помеха в радио — шлюз накапливает 30 секунд пакетов, потом резко выдаёт. Голый in-memory pipe без блокировки на upstream получает OOM, когда downstream не справляется. `Pipe.channel` в miniFlink имеет явный capacity — producer блокируется когда capacity исчерпан. Сеть-шлюз дольше держит запрос, но сервис не падает.

Объединение потоков с выравниванием watermark’a. Газовый пайплайн потребляет три источника — raw RSSI, окна локации, газ. У каждого свой event-time и свои watermark’и. Если их просто “склеить” (`Stream.append`), один поток обгонит другие, и состояние обогатится событиями “из будущего”. `Mf_event.union` выравнивает watermark по минимуму из подключенных потоков — ровно та семантика которая нужна, и которую *очень неприятно* писать руками каждый раз.

Параллелизация задним числом. Самое заметное. Изначальный ex07 написан в однопотоковом виде. Добавление параллельной обработки — это одна обёртка `Parallel.run_parallel_simple` вокруг готового пайплайна, без изменения бизнес-логики; см. раздел 5, где показано как одна и та же `Pipelines.median_rssi` ускорила в 4.17 раз на 8 воркерах после такой обёртки. Голый код пришлось бы переписывать, разбираться с гонками, перепродумывать state-shared-vs-per-key. Здесь же исходник остался байт-в-байт тем же.

Тестируемость. Stream это просто `unit -> 'a Mf_event.t option`. Тест пайплайна — `Mf_event.of_list ~ts list` с явными временами, потом `Stream.to_list` результата, потом проверка инвариантов. Голый код, использующий системное время и сетевые сокет, потребовал бы моков или медленных интеграционных тестов. У нас наш сложный газовый retract-пайплайн покрыт 7-ю сценариями за <10ms прогона.

Это не «библиотечная польза вообще». Это *конкретные* места, где наивный аналог даёт либо потерю данных, либо нестабильный дашборд, либо невозможность тестов. Каждое исправлять руками дорого; пакет работающих абстракций в miniFlink обходится дешевле.

1.4 Что есть готового в miniFlink

Кратко, чтобы не повторяться в дальнейших разделах — ниже полный inventory того, что мы используем в ex07:

- `Pipe.event_time ~lateness` — вставка watermark’ов в поток по event-time;
- `Pipe.dedup` — дедупликация по rule-функции;
- `Pipe.window_agg_keyed` с `allowed_lateness` — скользящие окна с retract’ами при опоздавших пакетах;

- `Agg.median`, `Agg.group_by`, `Agg.top_k_by` — набор комбинируемых агрегатов;
- `Pipe.process_keyed` — per-key state с self-timers (для FSM состояния шахтёра);
- `Mf_event.union` — объединение потоков с выравниванием watermark’a по минимуму;
- `Pipe.materialize` — сворачивание retract-богатого потока в финальную таблицу записей (для sink-a).

Чего *нет* — это бизнес-логики и доменных типов. Их пишем мы; структура ниже как раз и есть рассказ о том, как мы их написали.

1.5 Что увидим дальше

Статья идёт от внешнего наружу. В разделе 2 разбираем устройство входов: почему два независимых потока вместо одного, какие в них аномалии. В разделе 3 — три пайплайна по очереди: FSM состояния, скользящие окна с медианой и интерполяцией позиции, retract-обогащение газовых алертов. Раздел 4 собирает наблюдения о retract-семантике как о сквозном механизме, проходящем через все три пайплайна. Раздел 5 приводит измерения производительности (на машине автора-эксперимента и на пользовательском i7-8700 с OCaml 5) и описывает направленные оптимизации, которые мы делали. Раздел 6 — что отложено, что не делалось намеренно, и при каких условиях стоит реализовать недостающее.

2 Входы

В реальной системе входами выступают Kafka-топики, MQTT-брокеры, UDP-сокеты — что-то, что принимает байты с радио-сети шахты и дальше отдаёт их потребителю. В ex07 мы заменяем эту инфраструктурную часть на `Mock_source` — модуль, генерирующий *детерминированный* поток событий, неотличимый по форме от прода. Когда сервис переедет в minePASS-production, `Mock_source` меняется на `Kafka_source.read`, а *остальной код не трогается*. Это центральная идея ex07 — бизнес-логика не привязана к транспорту.

2.1 Два независимых потока, а не один

Первое и самое существенное решение — разнести RSSI-пакеты и газовые пакеты в два разных потока с разными типами.

```
module type S = sig
  val read      : unit -> packet      Mf_event.t Stream.t
  val read_gas  : unit -> gas_packet Mf_event.t Stream.t
  val stats     : unit -> string list
end
```

Почему не сделать единый `type telemetry = RSSI of packet | Gas of gas_packet` с одним потоком `read`? Сблaзн есть: один поток — одна точка консьюминга, проще архитектура источника. Не делаем по трём причинам.

Физически разные устройства. В реальном фонаре RSSI измеряется радиомодулем, газ — отдельным модулем на ремне (часто с собственным `batterypack`’ом). Они шлют пакеты независимо, через разные радиостанции на шлюз. Если объединять их в источнике — надо объединять в шлюзе, а это *дополнительная* логика на устройстве с ограниченным CPU. Дешевле оставить два потока.

Разные частоты и разный жизненный цикл. RSSI — 15 секунд между пакетами, газ — 10. Объединение через `union`-тип создаст поток с *неравномерной* структурой («два RSSI,

потом газ, потом RSSI...»), что усложняет понимание timing'a. Раздельные потоки имеют каждый свою регулярность.

Обогащение однонаправленное. Газовый пайплайн *потребляет* результат RSSI-пайплайна (координаты), но не наоборот. Если бы потоки были один, эта зависимость размывалась бы. А так в коде `Pipelines.gas_alerts` прямо принимает `~rssi`, `~locations`, `~gas` тремя именованными аргументами — видно что от чего зависит.

2.2 Структура RSSI-пакета

```
type packet = {
  lamp      : string;
  readings  : (string * float) list;
  voltage   : float;
  moving    : bool;
  sos       : bool;
  ts        : Time.t;
}
```

`lamp` — идентификатор фонаря, по нему идёт всё партиционирование (один шахтёр == один ключ). `ts` — event-time, миллисекунды от начала смены или от epoch (зависит от deployment).

`readings` — список пар (`beacon_id`, `rssi_dBm`). У шахтёра одновременно слышно от одного до пяти маяков (зависит от того, где он сейчас). Делать отдельную таблицу `packet` → `reading` с FK на пакет, как сделали бы в реляционной базе, нет смысла: пакет существует ровно как единое сообщение от устройства, и в потоке мы будем разворачивать его через `Pipe.flat_map` в плоский поток `reading`’ов.

`voltage`, `moving`, `sos` — метаданные о состоянии фонаря, обновляемые на каждом пакете. Это *не показания* в смысле RSSI, а отдельный класс данных (датчик ускорения, ADC батареи, кнопка). Они здесь потому что физически живут в том же пакете: радиомодуль фонаря один раз в 15 секунд просыпается и отправляет всё разом. Логически они потом расходятся по разным пайплайнам.

2.3 Структура газового пакета

```
type gas_packet = {
  g_lamp : string;
  g_ts   : Time.t;
  g_co2  : float option;
  g_co   : float option;
  g_h2   : float option;
  g_ch4  : float option;
}
```

Газы все `option` осознанно. У разных моделей газового модуля разный набор сенсоров: бюджетный имеет только CO и CH₄, дорогой — все четыре. Если бы поля были `float` с магической константой “нет данных” (например, -1.), это проникало бы во все downstream пайплайны и рано или поздно пробралось бы в финальный отчёт как “CO = -1 ppm”. С `option` компилятор не даст забыть `match` на `None`.

CO и CO₂ выражаются в ppm; H₂ и CH₄ — тоже, для единообразия (хотя в шахтёрской документации их часто пишут в объёмных процентах: 1% CH₄ = 10 000 ppm).

2.4 Дрожание канала

`Mock_source.Default` специально создаёт реалистичный поток, включая два класса аномалий:

- **Дубли** (около 3% от трафика): тот же (`lamp`, `ts`) приходит дважды. Имитирует поведение at-least-once Kafka и retry-логику UDP-шлюза.
- **Опоздавшие пакеты** (тоже около 3%): пакет доходит до сервиса *позже* чем должен по event-time. Сдвиг сделан таким, что опоздание превышает размер скользящего окна (≥ 90 секунд) — это гарантирует, что опоздавший пакет попадает в *уже закрытое* окно и порождает retract.

Это не «для красоты тестирования». Это для того, чтобы бенчмарки *отражали прод-нагрузку*. На раннем этапе в репозитории был отдельный `Clean`-источник без аномалий, с обоснованием «бенчмарку нужна стабильная нагрузка». Это было ошибкой: на чистом потоке dedup ничего не дедуплицирует, retract-логика никогда не срабатывает, и измеренный throughput *не отражает* реальной работы. Источник был удалён, а в коммит-сообщении явно записано почему. Этот эпизод хорошо иллюстрирует принцип: бенчмарк должен включать *цену корректности*, иначе он показывает несуществующую скорость, которая исчезает на проде.

2.5 Large_mine: масштабная конфигурация

`Mock_source.Default` даёт 6 шахтёров с тщательно проработанными индивидуальными сценариями — этого достаточно для демонстрации и регрессии, но мало для измерения производительности. Параллельно есть `Mock_source.Large_mine` — настраиваемая большая шахта:

```
let default_config = {
  horizons           = 16;
  beacons_per_horizon = 64;
  miners_per_horizon = 256;
  simulation_minutes  = 60;
  step_seconds        = 15;
  gas_period_seconds  = 10;
  pct_no_packets      = 0.10;
  pct_no_readings     = 0.05;
  pct_no_motion       = 0.20;
  pct_low_voltage     = 0.30;
  pct_sos             = 0.01;
  pct_gas_alerts      = 0.05;
  pct_duplicates      = 0.03;
  pct_late            = 0.03;
}
```

Шестнадцать горизонтов по 64 бикона = 1024 бикона; шестнадцать горизонтов по 256 шахтёров = 4096 шахтёров; час симуляции с шагом 15 секунд = около 949 000 RSSI-пакетов плюс газовые (шлются чаще). Это размер реальной большой шахты в Кузбассе.

Каждый шахтёр получает *детерминированный* сценарий через хеш своего ID — такие-то проценты попадают под каждый тип алерта, с непустыми пересечениями (один шахтёр может одновременно ронять батарейку и не двигаться). Детерминированность важна: повторный прогон бенчмарка даёт ровно те же события и ровно тот же результат, можно сравнивать через `git bisect`.

Биконы на горизонте. Маяк связи слышен только на *своём* горизонте — это упрощение, но не очень сильное: на практике межгоризонтная связь через породу настолько слабая, что её обычно специально подавляют, чтобы триангуляция не запуталась. Каждый шахтёр на своём горизонте слышит до пяти ближайших биконов по сеточному расположению. RSSI вычисляется детерминированно из расстояния по формуле $\text{RSSI} = -40 - 20 \log_{10}(d)$, и обращается обратно в расстояние в пайплайне локации — так `Large_mine` полностью внутренне-согласован.

Дальше мы переходим к самим пайплайнам.

3 Три пайплайна

Этот раздел ещё не написан.

4 Retract как сквозной механизм

Этот раздел ещё не написан.

5 Производительность

Этот раздел ещё не написан.

6 Выводы

Этот раздел ещё не написан.