

miniFlink: руководство для начала работы

Сквозной разбор от потока-функции до durable-пайплайна

Проект miniFlink

Аннотация

Это пошаговое руководство для тех, кто впервые видит miniFlink. Мы строим один пайплайн от начала до конца на сквозном примере — телеметрии температурных датчиков — и на каждом шаге добавляем ровно одно понятие: поток, событие и время, watermark, ключ группировки, окна, агрегацию, stateful-правила, дедупликацию и, наконец, персистентность. Все листинги взяты из компилируемого кода. Прочитав руководство сверху вниз, вы сможете читать и писать пайплайны miniFlink и будете знать, куда смотреть дальше. Примеры по возрастанию сложности живут в каталоге `examples/` (`ex01–ex10`); это руководство — сквозная нить, связывающая их.

Содержание

1	Введение: зачем нужна потоковая обработка	1
1.1	Два способа работать с данными	1
1.2	Что такое «поток»	1
1.3	Почему не просто запрос к базе раз в час?	2
1.4	Почему не просто Kafka или «напишу сам»?	2
1.5	Что даёт потоковый движок	3
1.6	Когда пакетная обработка — правильный выбор	3
1.7	Как читать дальше	3
2	Прежде чем начать	3
3	Шаг 1. Поток как функция	4
4	Шаг 2. Событие и время	4
5	Шаг 3. Watermarks	5
6	Шаг 4. Ключ группировки через KEYED	5
7	Шаг 5. Окна и агрегация	5
8	Шаг 6. Stateful-правила: триггеры	6
9	Шаг 7. Дедупликация поздних дублей	6
10	Шаг 8. Поздние данные: retract и update	6
11	Шаг 9. Персистентность без изменения пайплайна	7
12	Шаг 10. Масштабирование и exactly-once	7
13	Что дальше	8

1 Введение: зачем нужна потоковая обработка

Этот раздел не про код. Он объясняет простыми словами, что такое потоковая обработка, какую задачу она решает и почему для некоторых задач она удобнее привычных подходов — запросов к базе данных или самостоятельно написанной программы-обработчика. Если вы никогда не слышали этих слов — ничего страшного, начнём с нуля.

1.1 Два способа работать с данными

Представьте, что вы следите за своим банковским счётом. Узнать, что с деньгами что-то не так, можно двумя способами.

Способ первый. В конце месяца приходит выписка. Вы садитесь и просматриваете все операции разом. Картина полная и аккуратная: все траты, итоги, сравнение с прошлым месяцем. Но если в середине месяца кто-то украл карту и потратил деньги, вы узнаете об этом только сейчас — спустя недели, когда деньги уже ушли.

Способ второй. В ту самую секунду, когда происходит подозрительная операция, вам приходит сообщение: «с вашей карты пытаются снять крупную сумму в другом городе». Вы реагируете немедленно, пока ничего ещё не случилось.

Это не «хороший» и «плохой» способы. Это два разных инструмента для двух разных задач. Первый — *пакетная* обработка (по-английски batch): данные сначала накапливаются, а потом обрабатываются все сразу. Второй — *потоковая* обработка: каждое событие обрабатывается в тот момент, когда оно происходит, не дожидаясь остальных.

1.2 Что такое «поток»

Слово *поток* здесь стоит понимать буквально — как поток воды в реке. У реки нет «конца», который можно дожидаться: вода течёт постоянно. Точно так же во многих системах данные приходят непрерывно: датчик каждую секунду присылает температуру, касса пробивает чек за чеком, пользователи кликают по сайту круглые сутки. Каждую такую «каплю» — одно показание, один чек, один клик — мы будем называть *событием*.

Пакетный подход говорит: «накопим события за час (или за день), потом обработаем». Потоковый подход говорит: «обработаем каждое событие, как только оно появилось, и сразу обновим результат». Разница — как между «посмотреть утром вчерашнюю запись с камеры» и «охранник смотрит на мониторы прямо сейчас и реагирует на ходу».

1.3 Почему не просто запрос к базе раз в час?

Самый привычный способ работать с данными — сложить их в базу и писать запросы (обычно на языке SQL): «покажи среднюю температуру за последний час», «посчитай продажи за день». Для отчётов это прекрасно. Но если задача — *реагировать вовремя*, у такого подхода есть три слабых места.

Задержка. Если запрос запускается раз в час, то о проблеме вы узнаете в среднем через полчаса после того, как она случилась. Для отчёта это неважно. Для тревоги о перегреве оборудования или утечке газа — полчаса может быть слишком поздно.

Лишняя работа. Каждый раз запрос пересчитывает всё заново — перебирает все накопившиеся данные, даже если изменилась всего пара строк. Чем больше данных, тем тяжелее и дороже каждый прогон. Поток же обрабатывает только новое событие и просто *подправляет* уже посчитанный результат.

Самое тонкое — время. У каждого события есть два разных момента: когда оно *произошло на самом деле* и когда оно *дошло до вас*. В реальности данные опаздывают и приходят не по порядку: датчик в шахте мог измерить температуру в 14:00, но из-за плохой связи его показание добралось до сервера только в 14:05, уже после более свежих данных.

Если считать «по времени получения», легко сделать неверный вывод — например, «датчик молчал пять минут», хотя он просто не мог достучаться. Поточковые системы умеют рассуждать о времени *события*, а не о времени его получения, и аккуратно разбираться с опоздавшими данными. Сделать это правильно вручную — на удивление сложно.

1.4 Почему не просто Kafka или «напишу сам»?

Здесь часто звучит слово *Kafka*. Полезно понимать, что это такое и чем оно *не* является.

Kafka — это, если по-простому, очень надёжный конвейер (или почта) для сообщений. Одна программа кладёт события на конвейер, другая — снимает их с другого конца. Kafka гарантирует, что сообщения не потеряются и дойдут по порядку. Это отличный и важный инструмент — но он занимается *перевозкой* событий, а не их *осмыслением*. Kafka сам по себе не знает, что такое «среднее за минуту», не умеет группировать события в окна времени, не отличает дубликат от нового события и не подскажет, что делать с опоздавшим показанием.

Значит, всю эту логику кто-то должен написать в программе, которая читает события с конвейера. И вот тут кроется главная трудность. Вещи, которые на словах звучат просто, на практике полны подводных камней:

- считать «среднее за последнюю минуту» — нужно решить, что такое «минута», когда её закрывать и что делать с опоздавшими;
- не посчитать одно и то же дважды, если событие случайно пришло по конвейеру два раза;
- не сломаться, когда события приходят не по порядку;
- не потерять накопленные итоги, если программа перезапустилась (упала и поднялась снова).

Каждый из этих пунктов — источник тонких, незаметных ошибок, которые проявляются редко и в самый неудачный момент. Написанные руками с нуля, они почти наверняка где-то будут неверны.

1.5 Что даёт потоковый движок

Потоковый движок (Apache Flink — самый известный; miniFlink — компактная реализация той же идеи) — это набор готовых, проверенных «кирпичиков» ровно для этих задач: окна времени, подсчёты и средние, правила «подними тревогу, когда значение перешло порог», защита от дубликатов, аккуратная обработка опоздавших данных и сохранение состояния при перезапуске. Вы не пишете эту механику заново — вы *собираете* пайплайн из кирпичиков, а сложные и опасные детали уже решены внутри и покрыты тестами.

Важно и то, *как* это выглядит. Хорошо собранный потоковый пайплайн читается почти как описание задачи на человеческом языке: «сгруппируй по датчику, посчитай среднее за минуту, подними тревогу при перегреве». Не «как именно перебрать данные», а «что мы хотим получить». Именно к этому — чтобы код читался как спецификация — и стремится miniFlink. Дальше в руководстве вы увидите, что весь пайплайн — это короткая цепочка таких шагов.

1.6 Когда пакетная обработка — правильный выбор

Будет честно сказать и обратное. Поточковая обработка — не замена всему. Если задача — ночной отчёт, пересчёт зарплат раз в месяц, аналитика по историческим данным или разовая выгрузка — пакетный подход и обычный SQL проще, понятнее и полностью достаточны. Реагировать «прямо сейчас» там не нужно, а полная картина важнее скорости.

Потоковая обработка выигрывает там, где совпадают три вещи: данные поступают *непрерывно*, реагировать нужно *быстро*, и важно *время самих событий* (а также корректность при опозданиях, дубликатах и перезапусках). Мониторинг оборудования, обнаружение мошенничества, живые дашборды, оповещения о безопасности — классические примеры. Система мониторинга шахты, на операторах которой построено это руководство, — ровно такой случай.

1.7 Как читать дальше

Дальше мы построим один такой пайплайн от начала до конца на сквозном примере — показаниях температурных датчиков. Каждый следующий раздел добавляет ровно одно понятие из перечисленных выше: сначала «поток», потом «событие и время», потом окна, тревоги, защиту от дубликатов, обработку опоздавших данных и, наконец, сохранение состояния. К концу вы сможете читать и писать такие пайплайны сами. Технических терминов бояться не нужно — каждый вводится по одному и сразу на примере.

2 Прежде чем начать

miniFlink — это библиотека потоковой обработки на OCaml, реализующая ядро семантики Apache Flink на одном узле: событийное время, watermarks, окна, stateful-операторы, retract/update для поздних данных и exactly-once. Никакого брокера, планировщика или фонового цикла; весь пайплайн — это композиция обычных функций, которую можно читать как спецификацию.

Чтобы запускать примеры, нужен OCaml (4.14+ или 5.x) и Dune 3.0+. Соберите проект командой `dune build` и прогоните тесты — `dune test`. Каждый листинг ниже предполагает, что в начале файла стоит `open Miniflink`.

Сквозной пример. На протяжении всего руководства мы обрабатываем поток показаний температурных датчиков и хотим в итоге: считать среднюю температуру по датчику в окне, поднимать тревогу при перегреве и переживать перезапуск процесса без потери состояния. Доменная модель проста:

```
type reading = { sensor : string; celsius : float }
```

3 Шаг 1. Поток как функция

Центральная абстракция — `Stream.t`, и она устроена предельно просто:

```
type 'a t = unit -> 'a option
```

Поток — это функция без аргументов, которая при каждом вызове возвращает либо следующий элемент (`Some x`), либо `None`, если элементы кончились. Это *pull*-модель: ничего не происходит, пока потребитель не «потянет» следующее значение. Весь граф обработки — это стопка таких функций, обёрнутых одна вокруг другой.

```
let nats : int Stream.t =
  let i = ref 0 in
  fun () -> let v = !i in incr i; if v < 5 then Some v else None

let doubled = Stream.map (fun x -> x * 2) nats
```

`Stream.map`, `Stream.filter` и `Stream.flat_map` — это операторы преобразования: каждый принимает поток и возвращает новый поток, не вычисляя ничего заранее. Композиция через оператор `|>` читается естественно слева направо.

4 Шаг 2. Событие и время

Голый поток значений ничего не знает о времени. В потоковой обработке время — первоклассное понятие, поэтому `miniFlink` оборачивает значения в `Mf_event.t` с четырьмя вариантами:

- `Data (value, ts)` — значение с временной меткой (event-time);
- `Watermark ts` — отметка прогресса времени (см. шаг 3);
- `Retract (value, ts)` — отмена ранее выданного результата;
- `Update {old; new_value; ts}` — атомарная замена старого результата новым.

Последние два понадобятся, когда мы дойдём до поздних данных; пока что работаем с `Data`. Превратим наши показания в event-time поток — пусть каждое следующее чтение приходит на секунду позже:

```
let event_stream : reading Mf_event.t Stream.t =  
  readings  
  |> List.mapi (fun i r -> Mf_event.data r (i * 1000))  
  |> Stream.of_list
```

Временные метки здесь в миллисекундах; `Time` — это просто `int` мс с удобными конструкторами (`Time.seconds`, `Time.minutes`).

5 Шаг 3. Watermarks

Событийное время порождает вопрос: когда можно считать, что «все события до момента t уже пришли»? В распределённой системе данные опаздывают и приходят не по порядку. *Watermark* — это обещание системы: «событий с меткой меньше t больше не будет». Операторы окон используют его, чтобы понять, когда окно можно закрывать и эмитить результат.

```
let with_wm =  
  Mf_event.with_watermarks ~latency:(Time.seconds 1) event_stream
```

Параметр `~latency` задаёт допуск на опоздание: watermark отстаёт от максимальной увиденной метки на эту величину, что оставляет опоздавшим событиям шанс прийти. Чем больше `latency`, тем устойчивее к опозданиям, но тем позже закрываются окна — это прямой компромисс между полнотой и задержкой.

6 Шаг 4. Ключ группировки через KEYED

Почти все интересные операторы работают *по ключу*: окно «на датчик», агрегат «на пользователя». В большинстве фреймворков ключ передаётся параметром в каждый оператор. `miniFlink` кодирует ключ *один раз* в типе через first-class-модуль `Keyed.S`:

```

module By_sensor : Keyed.S with type t = reading = struct
  type t = reading
  let key r = r.sensor
end

```

Теперь `By_sensor` можно передавать операторам как значение, и им не нужен отдельный параметр `~key:`. Для разовых случаев есть `Keyed.of_fun (fun r -> r.sensor)`, не требующий объявления модуля. Этот приём и делает пайплайны похожими на спецификацию: ключ виден один раз, а не повторяется в каждом вызове.

7 Шаг 5. Окна и агрегация

Окно режет бесконечный поток на конечные куски, к которым можно применить агрегат. Простейшее — *тумблинг*: неперекрывающиеся окна фиксированного размера. Посчитаем среднюю температуру по каждому датчику в окнах по три секунды:

```

let avg_per_sensor =
  event_stream
  |> Pipe.window_agg (module By_sensor)
    (Pipe.tumbling (Time.seconds 3))
    (Agg.mean (fun r -> r.celsius))

```

`Pipe.window_agg` принимает модуль ключа, спецификацию окна (`tumbling`, `sliding`, и т. д.) и *агрегат*. Агрегаты — это композлируемая библиотека: `count`, `sum`, `mean`, `count_if`, а также комбинаторы вроде `both` (считать два агрегата сразу) и `contramap` (адаптировать входной тип). На выходе — поток (`string * 'r`): ключ и результат агрегата за закрытое окно. Результат появляется, когда `watermark` пересекает границу окна — вот зачем был нужен шаг 3.

8 Шаг 6. Stateful-правила: триггеры

Окна отвечают на «сколько/какое среднее», но для системы оповещения нужен *stateful*-автомат: поднять тревогу, когда значение пересекает порог, и снять её, когда вернулось в норму, не дёргая оператора на каждом событии. Это `Trigger`:

```

let alert_spec =
  Trigger.create
  ~name:"overheat"
  ~condition:(Trigger.greater_than 90.0)
  ~produce_alert:(fun ~key ~value ~ts:_ ->
    Printf.sprintf "ALERT %s=%.0f" key value)
  ~produce_recovery:(fun ~key ~ts:_ ->
    Printf.sprintf "OK %s" key)
  ()

let alerts =
  event_stream
  |> Stream.map (Mf_event.map_value (fun r -> (r.sensor, r.celsius))
  )
  |> Trigger.of_stream alert_spec

```

Триггер — это конечный автомат на ключ. Когда температура датчика превышает 90, он эмитит `Data` с алертом; когда падает обратно — `Retract` прежнего алерта и `Data` с `recovery`. Можно задать `debounce` (`~problem_for`), гистерезис (`greater_than_with_hysteresis`) и

произвольные условия (`custom`). Важное свойство, проверенное property-тестами: активных алертов на ключ не больше одного, а каждый `recover` парен своему алерту — автомат не «залипает».

9 Шаг 7. Дедупликация поздних дублей

Семантика `at-least-once` у источников означает дубли: один пакет может прийти дважды. `Pipe.dedup` подавляет повторы с одним ключом в пределах окна `cooldown`:

```
module By_pair : Keyed.S with type t = string * float = struct
  type t = string * float
  let key (k, _) = k
end

let deduped =
  event_stream
  |> Stream.map (Mf_event.map_value (fun r -> (r.sensor, r.celsius)))
  |> Pipe.dedup (module By_pair)
    ~rule:(fun (k, _) -> k)
    ~cooldown:(Time.seconds 5)
```

Свойство, зафиксированное property-тестом: между двумя прошедшими событиями одного ключа разрыв по времени не меньше `cooldown`, и каждое прошедшее событие действительно было во входе.

10 Шаг 8. Поздние данные: `retract` и `update`

Вернёмся к четырёхвариантному событию из шага 2. Что, если событие опоздало и пришло уже после закрытия его окна? Наивный вариант — выбросить его (потеря данных) или выдать новый результат поверх старого (дашборд «мигает» промежуточным состоянием). `miniFlink` делает третье: атомарно *корректирует* результат.

Когда в уже закрытое окно приходит позднее значение, оператор эмитит `Update` ($o \rightarrow n$) — одно событие, заменяющее старый результат o новым n без промежуточного состояния. Для потребителя это выглядит как мгновенный переход, без «мигания». Фундаментальный закон, который мы проверяем property-тестами для всех `stateless`-операторов:

$$\text{Update}(o \rightarrow n) \equiv \text{Retract}(o) \text{ затем } \text{Data}(n),$$

то есть атомарный `Update` — это в точности пара «отозвать старое, выдать новое», только без промежуточного шага. Писать обработку `Retract/Update` вручную обычно не нужно: операторы (`map`, `filter`, `window_agg`, `trigger`) делают это сами и согласованно.

11 Шаг 9. Персистентность без изменения пайплайна

Финальное требование: пережить перезапуск процесса. Активная тревога не должна исчезнуть из-за рестарта — иначе диспетчер увидит мнимое снятие.

Ключевая идея `miniFlink` — *ортогональная* персистентность: один и тот же пайплайн работает с `durability` и без неё, режим выбирается *снаружи*, а не вшит в операторы. Сначала пишем пайплайн как обычно:

```
let pipeline src =
  src
```

```
|> Stream.map (Mf_event.map_value (fun r -> (r.sensor, r.celsius)))
|> Trigger.of_stream alert_spec
```

Без персистентности — просто запускаем. С персистентностью — оборачиваем тот же вызов в durable-контекст:

```
(* в памяти, ничего не сохраняется *)
let ephemeral () = pipeline event_stream

(* то же самое, но состояние durable *)
let durable () =
  let backend = Persistence_backend.of_memory (Hashtbl.create 16) in
  Runtime_context.with_context
    (Runtime_context.durable backend)
    (fun () -> pipeline event_stream)
```

Пайплайн не изменился ни на строку — разница только в обёртке `with_context`. Сериализация тоже ортогональна: состояние операторов сериализуется по умолчанию (через `Marshal`), так что для `stash-recovery` не нужно писать ни одного кодека; для эволюции схемы между деплоями можно задать реестр кодеков в контексте, опять же не трогая пайплайн. В продакшене вместо in-memory backend подставляется RocksDB; пайплайн при этом снова не меняется.

Это свойство — что durable-прогон с «крашем» посередине даёт тот же результат, что непрерывный — мы проверяем property-тестом на сотнях случайных потоков и точек краша.

12 Шаг 10. Масштабирование и exactly-once

Всё выше — однопоточный пайплайн. Для пропускной способности `Parallel.run_parallel_simple` шардирует поток по ключу на N воркеров. Когда нужна не просто параллельность, а *exactly-once* с восстановлением после сбоя, используется `Checkpoint_parallel.run_exactly_once`: координатор инжектирует barrier-маркеры (снимок в стиле Chandy-Lamport), каждый воркер снапшотит своё состояние, а checkpoint фиксируется атомарно, когда снимки собраны со всех воркеров. Транзакционный sink и восстановление source по offset замыкают exactly-once на одном узле.

```
Checkpoint_parallel.run_exactly_once
  ~workers:4 ~capacity:256 ~checkpoint_every:1000
  ~key_of ~make_state ~process ~source ~sink ~store ()
```

Это другой, более высокий уровень гарантий, чем per-operator персистентность из шага 9: тот отвечает за восстановление состояния оператора, этот — за end-to-end exactly-once со стороны источника и приёмника. Выбирайте по задаче: для большинства пайплайнов достаточно ортогональной персистентности.

Замечание про параллелизм. На OCaml 4 истинной параллельности нет (runtime-lock), но конвейеризация через каналы прячет задержки; измеренное ускорение — $2.48\times$ на 4 воркерах. На OCaml 5 с `Domain` появляется реальный параллелизм, и тот же код пользуется им без изменений.

13 Что дальше

Вы прошли путь от потока-функции до durable-пайплайна с тревогами. Дальнейшие шаги:

- **Примеры.** Каталог `examples/` (`ex01–ex10`) идёт по возрастанию сложности; `ex07` — полноценный сервис мониторинга шахты с триангуляцией и retract-пайплайном газовых тревог.
- **Справочник API.** Интерфейсные файлы `.mli` (особенно `pipe.mli` и `trigger.mli`) написаны как самостоятельные руководства с разбором краевых случаев.
- **Глубже в семантику.** Статья `miniflink_article` разбирает устройство движка; `docs/orthogonal-persistence.md` — модель персистентности; `docs/atomic-update-event.md` — семантику `Update`.
- **Прикладной разбор.** Статья по `ex07` (`docs/ex07_article`) показывает, как из этих операторов собирается реальная система безопасности.

Главная мысль, которую стоит унести: пайплайн `miniFlink` читается как спецификация. Ключ объявлен один раз, время и поздние данные обработаны операторами, а решения о персистентности и параллелизме приняты снаружи и не засоряют логику. Это и есть та декларативность, ради которой всё затевалось.